C.E.S.A.R school

GUIA DE ESTUDO · TURMA A

FUNDAMENTOS DE ANÁLISE DE DADOS

Os 7 encontros explicados com calma, com exemplos, exercícios e respostas.

TURMA A · SEM PROGRAMAÇÃO · EXCEL SÓ COM CLIQUES

Especialização em Análise de Dados e Inteligência Artificial

Prof. Laura Pacífico · CESAR School

Sumário

· **Como usar este guia** 3

1 Fundamentos de Dados 4

O que é um dado 4
Dado, informação, conhecimento e decisão 4
Variáveis e seus tipos 6
Escalas de medição 7
Fontes de dados 9
Viés e representatividade 9
Boas práticas desde o início 10

2 Processo de Análise 13

O que é um processo analítico 13
Processo não é linha reta 14
Do problema à pergunta analítica 15
O que é uma boa pergunta 15
Cinco tipos de pergunta 16
Perguntas secundárias e hipóteses 17
Coleta: muito além de baixar uma planilha 17
O resto do caminho, em uma página 18
Checklist antes de analisar uma base 19

3 Limpeza I: qualidade e diagnóstico 21

As cinco dimensões da qualidade 21
O raio-X: diagnosticar antes de mexer 22
Valores ausentes 23
Duplicatas 24
Texto inconsistente 25
O log de limpeza 26

4 Limpeza II e Preparação 29

Quando a conta da própria base não fecha 29
Datas que não fecham 30
Impossível, suspeito ou raro 31
Outliers: fora da curva 31
Transformar números em faixas 33
Normalizar e padronizar 33

Uma data guarda várias informações 34
Colunas derivadas com propósito 35

5 Exploração de Dados 37

O que é explorar 37
Uma variável numérica: a distribuição 38
Boxplot sem mistério 39
Uma variável categórica: frequências 40
Comparar grupos 40
Duas variáveis numéricas: a dispersão 41
Duas variáveis categóricas: a tabela de contingência 42
Padrões no tempo 42
Escolher o gráfico certo 43
Da exploração às hipóteses 44

6 Estatística Descritiva 46

Tendência central: média, mediana e moda 46
Dispersão: o quanto os dados se espalham 48
Correlação: quando uma sobe, a outra sobe? 50
Do número ao insight 52

7 Projeto Integrador 55

O arquivo final, aba por aba 55
Revisão crítica do projeto 56
Limpeza, preparação e outliers com justificativa 56
Testar hipóteses e dar o veredito 57
Insights em quatro categorias 58
A conclusão para o gestor 59
Como o projeto é avaliado 59
Checklist de entrega 60

A Glossário 62

B Onde clicar no Excel 64

C Respostas dos exercícios 66

D Para continuar estudando 70

ANTES DE COMEÇAR

Como usar este guia

Este guia acompanha os 7 encontros de Fundamentos de Análise de Dados. Cada capítulo corresponde a um encontro e conta, com mais calma e mais exemplos, o que vemos em aula.

Você pode ler na ordem, como um livro, ou usar o sumário para voltar a um assunto quando precisar. Os exemplos usam as mesmas bases das aulas: uma base de clientes de uma loja, uma base de pedidos de uma loja online e uma base de entregas de um aplicativo de delivery. Assim, os números que aparecem aqui são os mesmos que você encontra nas aulas e no Excel.

Nesta disciplina você não precisa programar nem decorar fórmulas. As contas ficam com as aulas interativas e com o Excel; o seu trabalho é entender o que cada número significa e decidir o que fazer com ele. Quando uma conta aparece, ela vem num quadro opcional chamado **Por trás da conta**. Leia se tiver curiosidade; pode pular sem prejuízo.

Os quadros que aparecem pelo caminho

QUADRO	O QUE TRAZ
No Excel, só com cliques	O caminho no Excel usando menus, filtros e Tabela Dinâmica, sem escrever fórmula.
Por trás da conta	A conta que a ferramenta faz, explicada em palavras. Opcional.
Exemplo	Um caso resolvido com números reais da base.
Cuidado	Erros comuns e armadilhas de interpretação.
No projeto	O que aquele assunto pede no Projeto Integrador do seu grupo.

No fim de cada capítulo há um resumo e uma lista de exercícios. As respostas ficam no apêndice Respostas dos exercícios. Tente responder antes de olhar: errar e entender o porquê ensina mais do que acertar de primeira.

Convenções usadas no guia

- Números seguem o padrão brasileiro: vírgula para decimais e ponto para milhar (R$ 3.889,40).
- Nomes de colunas aparecem em `fonte de código`, como `renda_mensal`.
- Caminhos de menu do Excel usam setas: **Dados › Remover Duplicatas**.
- Correlação é classificada como fraca até 0,3, moderada de 0,3 a 0,6 e forte acima de 0,6, sem considerar o sinal.

ENCONTRO 1

1 FUNDAMENTOS DE DADOS

AO FINAL DESTE CAPÍTULO VOCÊ VAI SABER

- diferenciar dado, informação e conhecimento, e explicar como eles levam a uma decisão;
- classificar uma variável como qualitativa (nominal ou ordinal) ou quantitativa (discreta ou contínua);
- reconhecer as quatro escalas de medição e o que cada uma permite calcular;
- avaliar de onde vem um dado e que vieses ele pode carregar.

1.1 O que é um dado

Dado é qualquer registro de uma característica observável da realidade. Pode ser um número (37), uma palavra (Recife), uma data (12/03/2026), uma imagem ou um som. O que todos têm em comum é que registram algo que aconteceu, existe ou foi medido.

Sozinho, um dado é um fato isolado. O número 105 não diz nada: pode ser a idade de alguém (improvável), o número de uma casa, o preço de um produto ou os batimentos cardíacos de uma pessoa. Para virar algo útil, o dado precisa de contexto.

> **Antes de calcular, pergunte: que realidade este dado representa?**

Essa pergunta obriga a pensar em origem, contexto, limitações e significado. Ela evita o erro mais comum de quem começa: tratar números como se falassem por si.

1.2 Dado, informação, conhecimento e decisão

Um modelo clássico para pensar nisso é a pirâmide DIKW (do inglês *data, information, knowledge, wisdom*). Aqui usamos uma versão em escada, terminando na decisão, porque é para decidir que uma organização analisa dados.

- **Dado** é o registro bruto: 105.

- **Informação** é o dado com significado: 105 batimentos por minuto, medidos em repouso. Organizar, categorizar e contextualizar transformam dado em informação.
- **Conhecimento** é a informação interpretada com experiência: em repouso, 105 bpm está acima do normal para um adulto, o que caracteriza taquicardia.
- **Decisão** é o que se faz com o conhecimento: encaminhar a pessoa para avaliação médica.



Figura 1.1 · A mesma medida subindo a escada: o dado ganha unidade e contexto, vira interpretação e, por fim, ação.

E EXEMPLO

A mesma escada numa loja

Dado: o número 2 na coluna `satisfacao` de um cliente.

Informação: numa escala de 1 a 5, a nota média dos 200 clientes é 3,63, e 58% deram nota 4 ou 5.

Conhecimento: as notas baixas se concentram em quem esperou mais de 10 minutos pelo atendimento, como na tabela de cinco clientes da aula.

Decisão: reforçar a equipe nos horários de pico para reduzir a espera.

Por que dados importam

Dados reduzem incerteza. Eles permitem testar uma ideia antes de apostar nela, validar uma suposição e defender uma escolha com evidência, e não só com intuição.

DECIDIR SEM DADOS

- **Riscos elevados:** a experiência passada pode não valer no contexto atual.
- **Pressuposições não testadas:** crenças desatualizadas viram estratégia.
- **Ruído emocional:** decisões sob pressão ficam reativas e difíceis de repetir.

DECIDIR COM DADOS

- **Segurança:** a escolha tem base para ser justificada.
- **Velocidade:** com a evidência organizada, decide-se mais rápido.
- **Consistência:** critérios objetivos tratam casos parecidos do mesmo jeito.

1.3 Variáveis e seus tipos

Numa tabela, cada coluna é uma **variável**: uma característica que muda de um registro para outro. A cidade, a idade, o plano e a nota de satisfação de cada cliente são variáveis. Cada linha é uma **observação** (um cliente, um pedido, uma entrega).

Classificar a variável não é burocracia. O tipo decide quais resumos fazem sentido, que gráfico usar e que conclusão é válida.

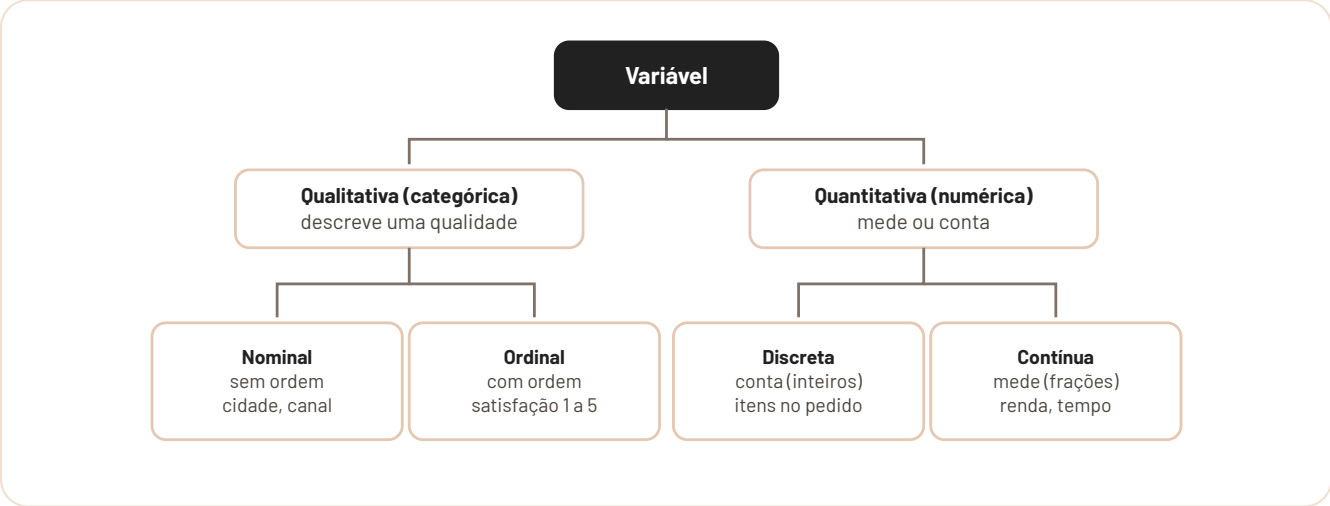


Figura 1.2 · Os quatro tipos de variável. A primeira divisão pergunta se a variável descreve uma qualidade ou mede uma quantidade.

Qualitativas (ou categóricas)

Descrevem qualidades, atributos ou categorias. Não fazem sentido em contas de soma ou média, mesmo quando aparecem como números.

- **Nominais:** categorias sem ordem natural. Cidade, canal de atendimento, cor, tipo de produto, forma de pagamento. Recife não é "maior" que Olinda.
- **Ordinais:** categorias com uma ordem clara, mas sem distância definida entre elas. Escolaridade (fundamental, médio, superior), nível de dor (leve, moderada, severa), satisfação de 1 a 5. Sabemos que 4 é melhor que 3, mas não que a distância entre 3 e 4 é igual à distância entre 1 e 2.

Quantitativas (ou numéricas)

Expressam quantidades medidas ou contadas. Permitem operações matemáticas: somar, tirar média, calcular variação.

- **Discretas:** resultado de contagem, normalmente números inteiros. Número de filhos, itens num pedido, chamados abertos no mês.
- **Contínuas:** resultado de medição, podem ter frações. Renda, peso, altura, tempo de entrega, temperatura.

> ! CUIDADO
>
> **Número nem sempre é quantidade**
>
> CEP, telefone, CPF, número do pedido e código do cliente são escritos com algarismos, mas são **identificadores**: servem para nomear, não para medir. A média dos CEPs de uma base existe como conta e não significa nada. Trate esses campos como qualitativos nominais.
>
> O contrário também acontece: uma nota de satisfação de 1 a 5 parece numérica, mas é ordinal. A média de notas é usada no dia a dia, com ressalva; o percentual de notas 4 e 5 costuma ser uma leitura mais honesta.

COLUNA	EXEMPLO	TIPO	POR QUÊ
`cidade`	Recife	Qualitativa nominal	Categorias sem ordem
`plano`	Básico, Plus, Premium	Qualitativa ordinal	Há uma ordem de nível
`satisfacao`	4	Qualitativa ordinal	Escala de opinião de 1 a 5
`idade`	39	Quantitativa discreta	Anos completos, contados
`renda_mensal`	3.889,40	Quantitativa contínua	Valor medido, com centavos
`id_cliente`	C0001	Identificador	Nomeia o cliente
`data_cadastro`	21/01/2025	Temporal	Marca um momento no tempo

1.4 Escalas de medição

Além do tipo, cada variável tem uma escala de medição. São quatro, e cada uma libera tudo o que a anterior permite e mais alguma coisa.

ESCALA	O QUE ELA TEM	EXEMPLOS	O QUE FAZ SENTIDO
Nominal	Só categorias distintas	cidade, cor, canal	Contagem, percentual, moda

ESCALA	O QUE ELA TEM	EXEMPLOS	O QUE FAZ SENTIDO
Ordinal	Categorias com ordem	escolaridade, satisfação 1 a 5, ranking	Tudo acima + mediana e percentis
Intervalar	Ordem e distâncias iguais, sem zero absoluto	temperatura em °C, ano do calendário	Tudo acima + média e desvio padrão
Razão	Tudo acima + zero absoluto	renda, peso, tempo, quantidade	Todas as operações, inclusive razões ("o dobro")

A diferença entre intervalar e razão está no zero. Zero grau Celsius não é "ausência de temperatura", por isso 20 °C não é "o dobro" de 10 °C. Já zero reais é ausência de dinheiro, então R$ 2.000 é de fato o dobro de R$ 1.000.

O que faz sentido calcular

Juntando tipo e escala, chegamos à pergunta prática: que resumo usar para cada coluna?

TIPO DA COLUNA	RESUMOS ADEQUADOS	EVITE
Nominal	Contagem, percentual, moda	Média, mediana
Ordinal	Contagem, percentual, moda, mediana	Média sem ressalva
Discreta e contínua	Média, mediana, mínimo, máximo, desvio padrão	Moda em valores contínuos (quase nunca se repetem)
Identificador	Contagem de registros, contagem de valores distintos	Qualquer conta com o valor
Temporal	Contagem por dia, mês ou ano; primeiro e último registro; intervalos	Somar datas

Dados temporais

Datas, horários e carimbos de tempo merecem atenção especial. Eles têm ordem e permitem calcular intervalos (dias entre o pedido e a entrega), e é por eles que enxergamos tendências, sazonalidade e ciclos. Em análise de negócios, "quando?" costuma ser tão importante quanto "quanto?" e "o quê?". Uma data também guarda várias informações dentro dela (ano, mês, dia da semana), como você verá no Capítulo 4.

1.5 Fontes de dados

Saber de onde o dado veio e como foi coletado é o primeiro passo para decidir se dá para confiar nele. As fontes mais comuns são estas.

Os dados também variam na estrutura. **Estruturados** já vêm em linhas e colunas, como uma planilha. **Não estruturados** são textos livres, imagens e áudios, e precisam de processamento antes de virar tabela. Nesta disciplina trabalhamos com dados estruturados.

FONTE	EXEMPLOS	VANTAGEM	CUIDADO
Internas	CRM (clientes, interações, compras), ERP (finanças, estoque, RH), planilhas de controle	Falam diretamente do negócio	Planilhas manuais acumulam erros de digitação e padrões diferentes
Públicas	IBGE, Portal Brasileiro de Dados Abertos, Base dos Dados, DATASUS	Gratuitas e com metodologia publicada	Podem estar desatualizadas ou num nível de detalhe diferente do que você precisa
Digitais e comportamentais	Logs de acesso, cliques e navegação, redes sociais, carrinhos abandonados	Volume grande e coleta automática	Medem comportamento, não intenção; bots e contas duplicadas distorcem
APIs	Dados de clima, de pagamento, de redes sociais, de mapas	Atualizadas e com formato padronizado	Limites de uso, mudanças de versão, dependência de terceiros
Web scraping	Preços publicados em sites, avaliações de produtos	Útil quando não existe API	Respeitar os termos de uso dos sites e a LGPD

1.6 Viés e representatividade

Um dado pode estar correto e ainda assim contar uma história errada, se ele não representa o grupo sobre o qual queremos concluir. Isso é **viés**. Os quatro tipos mais comuns:

- **Viés de coleta:** a amostra não representa a população. Uma pesquisa só online exclui quem não usa internet.
- **Viés de registro:** a forma de registrar favorece um resultado. Perguntas tendenciosas ou categorias mal definidas.
- **Viés de contexto:** o momento e o lugar da coleta afetam a resposta. Uma pesquisa de satisfação feita logo após uma falha no sistema.
- **Viés de processamento:** escolhas na limpeza mudam o resultado. Remover valores extremos que eram reais, por exemplo.

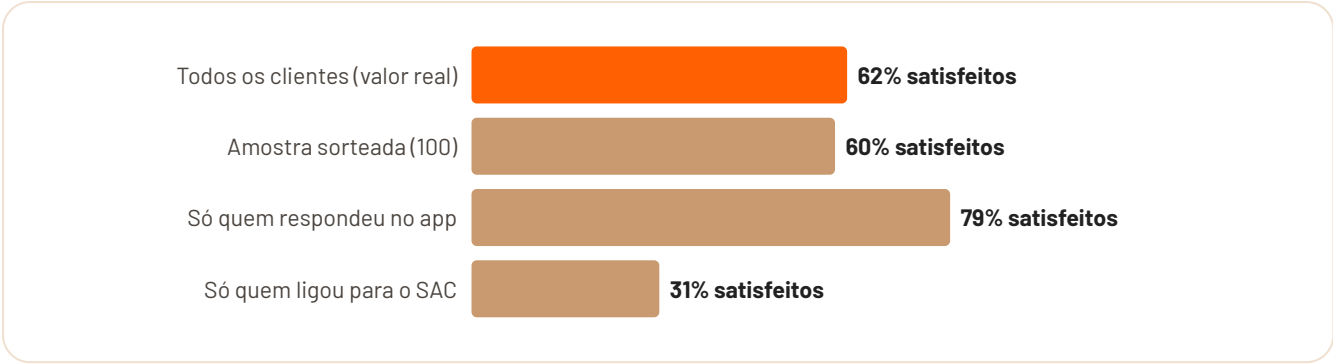


Figura 1.3 · Exemplo ilustrativo: a mesma pergunta ("você está satisfeito?") feita a grupos diferentes de uma loja com 1.000 clientes. Só a amostra sorteada chega perto do valor real.

Também importa o tamanho. Com poucos casos, qualquer padrão parece forte. No primeiro encontro, olhamos cinco clientes: todos que esperaram até 10 minutos voltaram a comprar e nenhum dos que esperaram mais voltou. Com duzentos clientes, a diferença continua, mas fica bem menor.

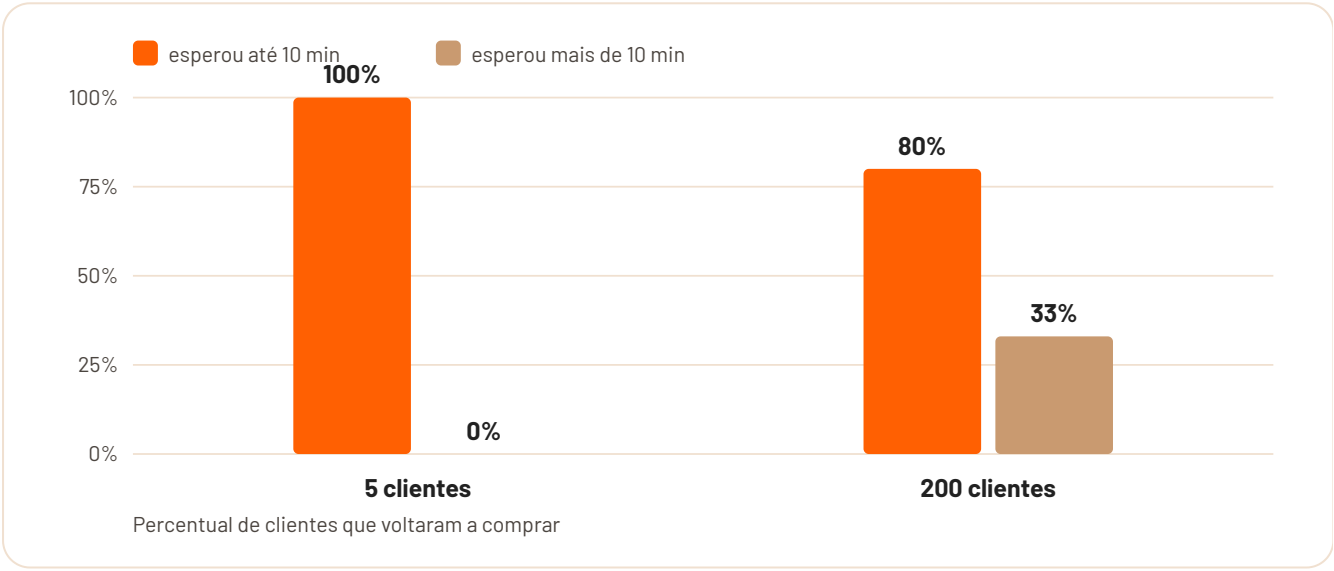


Figura 1.4 · Com 5 clientes, a diferença parece absoluta (100% contra 0%). Com 200, ela existe, mas é menor (80% contra 33%). Poucos dados exageram padrões.

1.7 Boas práticas desde o início

Hábitos simples, adotados no primeiro dia, evitam problemas sérios depois.

1. **Documente tudo.** Para cada variável, registre o que ela representa, a unidade, os valores possíveis, a data e a fonte da coleta, as transformações feitas e as limitações conhecidas. Esse registro é o **dicionário de dados** (ou metadados).
2. **Verifique a qualidade.** Nunca assuma que a base está pronta. Procure vazios, erros de digitação, formatos misturados e repetições antes de qualquer conta.
3. **Questione a fonte.** De onde veio? Quem coletou e com que objetivo? Representa todos ou só uma parte? Quando foi coletado? Ainda vale?

4. **Controle os vieses.** Pergunte quem ficou de fora da base e se isso muda a conclusão.
5. **Comece pequeno.** Olhe as primeiras linhas, entenda a estrutura e teste seus passos numa amostra antes de rodar na base inteira.

FLUXO IMPROVISADO

1. Abrir a planilha
2. Criar vários gráficos
3. Procurar algo interessante
4. Tentar justificar uma conclusão

FLUXO RECOMENDADO

1. Entender o problema
2. Definir a pergunta
3. Selecionar os dados
4. Analisar e interpretar
5. Comunicar e recomendar

A ferramenta vem depois da pergunta.

X NO EXCEL, SÓ COM CLIQUES

Primeiro contato com uma base

1. Dê dois cliques no arquivo .csv. Se as colunas aparecerem todas juntas numa só, abra pelo caminho **Dados › Obter Dados › De Arquivo › De Texto/CSV** e escolha o delimitador "Ponto e vírgula".
2. Clique em qualquer célula da base e use **Página Inicial › Formatar como Tabela** (ou `Ctrl` + `Alt` + `T`). Confirme que a tabela tem cabeçalhos. As setas de filtro aparecem em cada coluna.
3. Clique numa célula de cada coluna e olhe o formato no grupo **Página Inicial › Número**: Geral, Número, Data ou Texto.
4. Repare no alinhamento: números e datas ficam à direita; texto fica à esquerda. Um "número" alinhado à esquerda está guardado como texto e não entra nas contas.
5. Clique na letra de uma coluna numérica e olhe a barra de status, no canto inferior direito: o Excel mostra Média, Contagem e Soma sem nenhuma fórmula.

P NO PROJETO

No Projeto Integrador, o grupo vai montar um **dicionário de variáveis** da sua base na aba 0_Documentação: nome da coluna, tipo, escala, descrição e valores possíveis. Classificar bem agora evita calcular a média de um código ou ignorar a ordem de uma escala mais adiante.

Para revisar

- Dado é registro bruto; informação é dado com contexto; conhecimento é informação interpretada; a decisão é o objetivo de tudo.
- Variáveis qualitativas podem ser nominais (sem ordem) ou ordinais (com ordem). Quantitativas podem ser discretas (contagem) ou contínuas (medição).
- Identificadores como CEP e código são escritos com números, mas não são quantidades.
- As escalas nominal, ordinal, intervalar e razão vão liberando operações. Só a razão tem zero absoluto.
- Toda fonte tem vantagens e armadilhas. Pergunte quem ficou de fora da base.
- Poucos dados exageram padrões.

Exercícios

1. Classifique quanto ao tipo e à escala: (a) temperatura em graus Celsius; (b) tempo de reação em milissegundos; (c) cargo na empresa (estagiário, analista, coordenador, gerente); (d) nível de escolaridade.
2. Uma colega calculou a média da coluna `cep_cliente` e obteve 52.970.974. O que você diria a ela?
3. Para cada coluna, diga o melhor resumo: (a) `canal` de atendimento; (b) `satisfacao` de 1 a 5; (c) `renda_mensal` numa base com alguns clientes muito ricos; (d) `data_cadastro`.
4. Dê um exemplo da escada dado → informação → conhecimento → decisão para o tempo de entrega de um aplicativo de delivery.
5. Uma empresa quer saber se os clientes estão satisfeitos e coloca a pesquisa só na tela de confirmação de compra do aplicativo. Que viés isso pode gerar?
6. Observe a tabela de cinco clientes da aula: A (5 min, nota 9, WhatsApp, voltou), B (18 min, nota 5, Telefone, não voltou), C (12 min, nota 6, WhatsApp, não voltou), D (4 min, nota 10, Site, voltou), E (22 min, nota 4, Telefone, não voltou). Que insight parece surgir e que cuidado você teria antes de agir?

ENCONTRO 2

2 PROCESSO DE ANÁLISE

AO FINAL DESTE CAPÍTULO VOCÊ VAI SABER

- descrever as etapas do processo analítico e por que ele é um ciclo;
- transformar um problema de negócio numa pergunta que os dados conseguem responder;
- escrever perguntas secundárias e hipóteses testáveis;
- planejar e documentar a coleta, escolhendo o nível de detalhe certo.

2.1 O que é um processo analítico

Um processo analítico é um conjunto de etapas interligadas que transforma dados brutos em decisões. Ele também funciona como um roteiro mental: diz o que perguntar, o que conferir e como comunicar.

As etapas clássicas são seis:

1. **Pergunta:** definir o problema e o que precisamos saber para decidir.
2. **Coleta:** encontrar os dados, avaliar se são confiáveis e registrar de onde vieram.
3. **Preparação:** limpar e transformar os dados até que possam ser analisados (Capítulo 3 e Capítulo 4).
4. **Exploração (EDA):** olhar os dados com curiosidade para entender como se comportam e levantar hipóteses (Capítulo 5).
5. **Análise:** responder à pergunta com as técnicas adequadas (Capítulo 6).
6. **Comunicação:** transformar resultados em recomendações que alguém consiga usar (Capítulo 7).

Por que seguir um processo

Processos reduzem erros, porque criam pontos de conferência. Aceleram projetos, porque evitam retrabalho. Criam consistência, porque a qualidade não depende de quem está analisando nem do dia. E permitem que outra pessoa entenda, confira e refaça o que você fez.

Sem processo, os problemas se repetem: análises refeitas por falta de registro, conclusões diferentes a partir da mesma base, tempo perdido e, no pior caso, decisões erradas baseadas em análises mal conduzidas.

! CUIDADO

Não pule etapas

Pular a preparação deixa erros contaminarem tudo o que vem depois. Pular a exploração leva a conclusões apressadas. Pular a pergunta produz uma análise sem propósito, que até pode estar certa, mas não serve para nada.

2.2 Processo não é linha reta

Quem começa costuma imaginar a análise como uma esteira: cada etapa termina e passa para a próxima. Na prática ela é um ciclo. Voltar atrás não é falha; é parte do refinamento.



Figura 2.1 · As seis etapas em sequência. As setas laranja tracejadas mostram dois retornos comuns: a exploração revela que falta um dado e a análise sugere uma pergunta melhor. A seta cinza mostra que a comunicação abre perguntas novas e o ciclo recomeça.

Situações típicas que fazem voltar:

- **Novas perguntas:** a análise mostra algo inesperado e a pergunta original fica pequena.
- **Falhas na coleta:** você percebe que falta uma variável ou que um período não foi coletado.
- **Problemas na limpeza:** a exploração revela erros que passaram despercebidos.
- **Necessidade de refinar:** o resultado está certo, mas ainda não ajuda a decidir.

A postura que ajuda é a de investigador: questionar suposições, testar hipóteses com dados, revisar conclusões diante de novas evidências e validar resultados antes de comunicá-los.

2.3 Do problema à pergunta analítica

Toda análise começa com uma pergunta. O problema de negócio costuma ser amplo e ligado a uma dor: “estamos perdendo clientes”. A pergunta analítica é específica e pode ser respondida com dados: “a perda aumentou em quais meses?”, “quais perfis cancelam mais?”, “existe diferença por canal?”.

Um bom jeito de fazer essa tradução é montar uma cadeia de quatro elos, começando pela decisão:

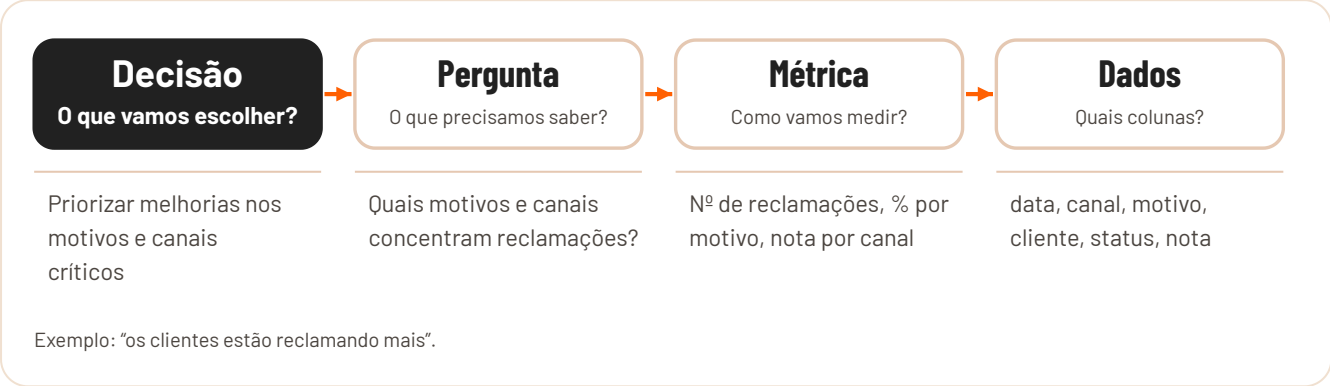


Figura 2.2 · A cadeia começa pela decisão que a análise vai apoiar. Cada elo responde ao anterior.

CAMADA	EXEMPLO: “OS CLIENTES ESTÃO RECLAMANDO MAIS”
Problema	Os clientes estão reclamando mais.
Pergunta principal	Quais motivos concentram mais reclamações e em quais canais?
Métricas	Quantidade de reclamações, percentual por motivo, nota média por canal.
Dados necessários	Data, canal, motivo, cliente, status, nota, tempo de resposta.
Decisão possível	Priorizar melhorias nos motivos e canais mais críticos.

Quem define a pergunta raramente é só o analista. Ela nasce da área de negócio que tem a necessidade, do gestor que vai decidir, do cliente que tem o problema e do contexto da organização. O papel do analista é lapidar essa necessidade até que ela possa ser respondida.

2.4 O que é uma boa pergunta

Uma boa pergunta tem quatro qualidades:

1. **Específica:** foca num aspecto definido, sem ser vaga.
2. **Mensurável:** pode ser respondida com dados concretos.
3. **Relevante:** a resposta muda alguma decisão.
4. **Conectada ao contexto:** considera período, público e quem vai usar a resposta.

PERGUNTA FRACA

“Quero analisar vendas.”

Vaga, sem foco, sem período, não sugere nenhuma ação.

PERGUNTA BOA

“Quais produtos tiveram queda de vendas nos últimos 3 meses e por quê?”

Específica, mensurável, com período definido e busca a causa.

E EXEMPLO

Refinando uma pergunta passo a passo

Ponto de partida: “Queremos entender a evasão escolar.”

Com público: “Queremos entender a evasão de alunos do ensino médio.”

Com período: “... nos últimos 2 anos.”

Com o que medir: “Quais fatores socioeconômicos e acadêmicos estão mais associados à evasão de alunos do ensino médio nos últimos 2 anos ...”

Com ação: “... e quais intervenções podem reduzi-la?”

A versão final tem especificidade (ensino médio), tempo (2 anos), mensurabilidade (fatores quantificáveis) e orientação para ação (intervenções).

Erros comuns nesta etapa: perguntar de forma vaga (“me mostre tudo sobre os clientes”), não saber o que fazer com a resposta quando ela chegar e analisar só porque “parece interessante”. Antes de seguir, confira: a pergunta é específica o bastante? Dá para medi-la com os dados disponíveis? A resposta vai gerar alguma ação?

2.5 Cinco tipos de pergunta

Reconhecer o tipo da pergunta ajuda a escolher a técnica e os dados.

TIPO	PERGUNTA QUE FAZ	EXEMPLO
Descritiva	O que aconteceu?	Quantos atendimentos tivemos por canal no mês?
Diagnóstica	Por que pode ter acontecido?	Por que o tempo de espera no telefone aumentou?
Comparativa	Há diferença entre grupos?	A satisfação muda por região?
Temporal	Como evoluiu no tempo?	As reclamações aumentaram em quais meses?
Preditiva	O que pode acontecer?	Quem tem maior risco de cancelar no próximo mês?

Há ainda a pergunta **prescritiva**, "o que devemos fazer?", que combina as anteriores para recomendar uma ação. Nesta disciplina, as perguntas preditivas e prescritivas aparecem como horizonte; o foco está nas descritivas, comparativas, temporais e diagnósticas.

2.6 Perguntas secundárias e hipóteses

A pergunta principal costuma ser grande demais para ser respondida de uma vez. As **perguntas secundárias** a quebram em partes menores, cada uma respondível com uma análise. Para a pergunta "quais fatores estão associados a entregas mais demoradas?", as secundárias poderiam ser: "a distância influencia o tempo?", "quando chove, a entrega demora mais?", "entregadores mais experientes são mais rápidos?".

Uma **hipótese** é uma resposta provisória que o grupo pretende testar. Hipótese não é conclusão: ela pode ser confirmada, refutada ou ficar sem resposta. Para ser útil, a hipótese precisa ser **testável**:

- nomeia as variáveis envolvidas (distância e tempo de entrega);
- diz a direção esperada (quanto maior a distância, maior o tempo);
- todas as variáveis existem, ou podem existir, na base.

HIPÓTESE FRACA

"A chuva atrapalha as entregas."

Atrapalha como? No tempo, na nota, nos cancelamentos?

HIPÓTESE TESTÁVEL

"Em dias de chuva, o tempo médio de entrega é maior."

Variáveis claras (chuva e tempo) e direção definida.

Para cada hipótese, liste as **variáveis ideais**: as colunas de que você precisaria para testá-la. Comparar essa lista com a base que você realmente tem mostra, logo no início, o que dá e o que não dá para responder.

2.7 Coleta: muito além de baixar uma planilha

Coletar envolve entender a fonte, avaliar se ela é confiável, verificar os metadados, conferir se os dados estão completos e registrar como tudo foi feito.

Dados ideais são

- **relevantes** para a pergunta;
- **completos**, sem lacunas críticas;
- **organizados** de forma lógica;
- **confiáveis**, de fonte verificada;
- **atualizados** para o período da análise;
- **documentados**, com dicionário.

Riscos de uma coleta ruim

- **Viés:** dados que não representam a realidade.
- **Falta de representatividade:** a amostra não reflete o público.
- **Ruídos e erros:** inconsistências e duplicações que contaminam a análise.

Registrar a coleta é tão importante quanto coletar. Uma boa ficha de coleta tem: **data e hora** da extração, **fonte** (sistema, URL ou API), **método** (como foi extraída), **responsável** e **observações** (anomalias e particularidades encontradas).

Granularidade: qual nível de detalhe você precisa?

Granularidade é o nível de detalhe de cada linha da base. As mesmas vendas de uma cafeteria podem estar registradas de quatro formas:

CADA LINHA É	GRANULARIDADE	AINDA RESPONDE	JÁ NÃO RESPONDE
Uma venda, com horário	Alta	Horário de pico, ticket por venda, produto mais vendido de manhã	—
Um produto por dia	Média	Produto mais vendido, dias fortes e fracos	Horário de pico, ticket por venda
Um dia	Média-baixa	Dias fortes e fracos, faturamento diário	Qual produto vende mais
Um mês	Baixa	Faturamento do mês	Quase todas as perguntas do dia a dia

Mais detalhe permite mais análises, mas dá mais trabalho e ocupa mais espaço. A regra prática: **dá para agregar depois, mas não dá para desagregar**. Se houver dúvida, colete no nível mais detalhado que a pergunta pode precisar.

2.8 O resto do caminho, em uma página

As próximas etapas ganham capítulos próprios. Aqui vai a visão geral, para você saber aonde estamos indo.

- **Limpeza e preparação.** Limpar é corrigir problemas (erros, vazios, duplicatas, formatos). Preparar é transformar a base para a análise (criar colunas, juntar tabelas, mudar escalas). Costuma tomar a maior parte do tempo de um projeto.
- **Exploração.** Entender como cada variável se distribui, onde está o centro, quanto ela varia, que valores são extremos e quais variáveis andam juntas.
- **Análise.** Responder formalmente à pergunta: descrever, comparar grupos, investigar causas. Testes estatísticos que permitem generalizar para além da base (análise inferencial) ficam como próximo passo depois desta disciplina.
- **Comunicação.** Um número sozinho não gera ação. Insight é significado: uma narrativa clara, com visual limpo, que termina numa recomendação.

E o ciclo recomeça: cada resposta tende a abrir uma pergunta nova, mais precisa que a anterior.

2.9 Checklist antes de analisar uma base

✓ Qual decisão esta análise deve apoiar?	✓ Quem ou o que está representado na base?
✓ Qual pergunta queremos responder?	✓ Há campos vazios, duplicados ou suspeitos?
✓ De onde vieram os dados?	✓ Quais variáveis são mais importantes?
✓ Qual período está coberto?	✓ Que conclusão esta base **não** permite tirar?

P NO PROJETO

O canvas do projeto

No Encontro 2 o grupo escolhe o tema e monta o **canvas do projeto**, que vai para a aba 0_Documentação:

- **Tema:** por exemplo, atrasos de entrega num aplicativo de delivery.
- **Pergunta principal:** quais fatores estão associados a entregas mais demoradas e a notas mais baixas?
- **Perguntas secundárias** (3 ou 4): a distância influencia o tempo? A chuva aumenta o tempo? O canal do pedido muda a nota?
- **Hipóteses** (uma por pergunta secundária): quanto maior a distância, maior o tempo de entrega; pedidos em dias de chuva demoram mais.
- **Variáveis ideais:** distância, tempo de entrega, chuva, canal, nota do cliente, experiência do entregador, data do pedido.

Esse canvas é o ponto de partida de tudo. No Encontro 7 o grupo volta a ele para avaliar se a pergunta foi bem formulada e se a base respondeu o que prometia.

Para revisar

- O processo analítico vai da pergunta à comunicação, em seis etapas, e funciona como ciclo.
- Problema de negócio é amplo; pergunta analítica é específica e respondível com dados.
- A cadeia decisão → pergunta → métrica → dados garante que a análise sirva para alguma coisa.
- Boa pergunta: específica, mensurável, relevante e conectada ao contexto.
- Hipótese testável nomeia as variáveis, diz a direção e depende de dados que existem.
- Registre a coleta. Na dúvida, colete no maior nível de detalhe: agregar depois é fácil, desagregar é impossível.

Exercícios

1. Transforme o problema “nossas vendas online caíram” em uma pergunta principal e três perguntas secundárias.
2. Classifique o tipo de cada pergunta: (a) quantos pedidos foram cancelados em março?; (b) por que o tempo de espera no telefone aumentou?; (c) a satisfação dos clientes de Recife é diferente da de Caruaru?; (d) as vendas cresceram mês a mês no último ano?; (e) quais clientes têm maior chance de cancelar no próximo mês?
3. Reescreva como hipótese testável: “o app é melhor que o telefone”.
4. Monte a cadeia decisão → pergunta → métrica → dados para uma escola que quer reduzir a evasão.
5. Durante a exploração de uma base de vendas, você percebe que não há a coluna de canal de venda, essencial para a sua pergunta. Para qual etapa do processo você volta, e o que faz lá?
6. Uma rede de lojas guarda apenas o faturamento total de cada mês. Cite duas perguntas que essa base responde e duas que ela não responde.

ENCONTRO 3

3 LIMPEZA I: QUALIDADE E DIAGNÓSTICO

AO FINAL DESTE CAPÍTULO VOCÊ VAI SABER

- avaliar uma base pelas cinco dimensões da qualidade;
- fazer o diagnóstico (o raio-X) de uma base antes de mexer nela;
- escolher e justificar uma estratégia para valores ausentes;
- tratar duplicatas exatas e parciais e padronizar categorias escritas de formas diferentes;
- registrar cada decisão num log de limpeza.

A análise só é tão boa quanto os dados. Limpar e preparar costuma tomar a maior parte do tempo de um projeto, e é a etapa mais crítica: um erro aqui contamina tudo o que vem depois. Este capítulo usa a base de clientes do Encontro 3 (`clientes_encontro3.csv`), com 210 linhas e 12 colunas, que tem de propósito os problemas mais comuns do dia a dia.

3.1 As cinco dimensões da qualidade

Qualidade de dados não é uma coisa só. Ela é avaliada em cinco dimensões, e cada uma responde a uma pergunta.

DIMENSÃO	PERGUNTA	PROBLEMA NA BASE DE CLIENTES
Precisão	Os valores representam a realidade?	Idade de 210 anos, renda negativa, satisfação 7 numa escala de 1 a 5
Completude	Os dados necessários estão lá?	18 clientes sem renda; 133 sem segundo telefone
Consistência	Seguem o mesmo padrão e não se contradizem?	Recife escrito de várias formas; última compra antes do cadastro
Atualidade	São recentes o bastante?	Datas de cadastro no futuro, que ainda não aconteceram
Unicidade	Cada cliente aparece uma vez só?	6 linhas copiadas e 4 clientes repetidos com dados diferentes

Por que a base chega assim

Quase nunca é descuido de uma pessoa só. Os problemas nascem no caminho entre o mundo real e a planilha:

- **Erros humanos:** digitação, campo preenchido no lugar errado, interpretação diferente do que se pedia.
- **Sistemas desconectados:** o mesmo cliente cadastrado em dois sistemas que não conversam.
- **Falta de padrão:** ninguém definiu como escrever a cidade ou o formato da data.
- **Extração inadequada:** uma exportação que corta acentos, troca separadores ou duplica linhas.
- **Falhas de integração:** ao juntar fontes com estruturas diferentes, campos se desalinham.

3.2 O raio-X: diagnosticar antes de mexer

Antes de corrigir qualquer coisa, olhe a base inteira e faça um diagnóstico. Três passos:

1. **Veja uma amostra.** Role pelas primeiras 20 ou 30 linhas para entender a estrutura.
2. **Confira as colunas.** Nomes, tipos e se fazem sentido. Um número alinhado à esquerda, por exemplo, está guardado como texto.
3. **Procure incongruências.** Valores impossíveis, negativos onde não deveriam, datas no futuro, categorias escritas de formas diferentes.

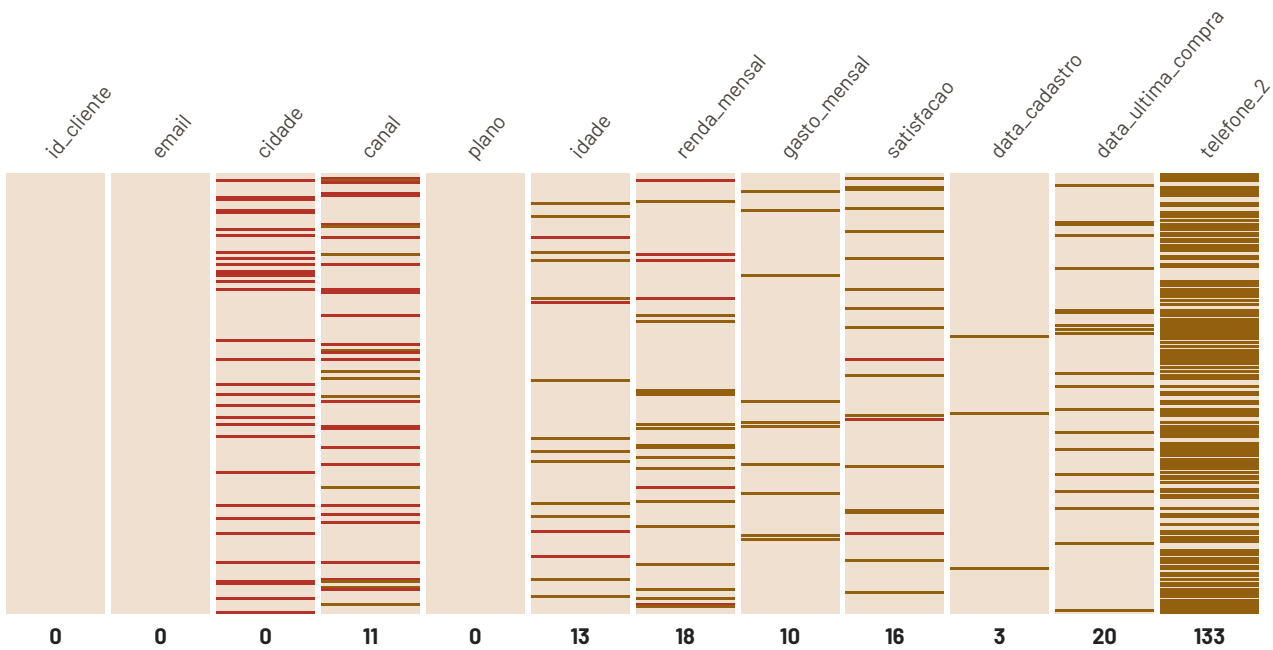


Figura 3.1 · Mapa da base de clientes: cada faixa vertical é uma coluna e cada risco horizontal é uma linha. Dá para ver de relance onde estão os vazios e os valores com problema.

O mapa mostra algo que uma tabela de números esconde: `telefone_2` está quase toda vazia (63%), enquanto as outras colunas têm poucos vazios espalhados. Essa diferença vai pedir decisões diferentes.

3.3 Valores ausentes

Valor ausente é o dado que deveria estar lá e não está. Ele aparece de várias formas: célula vazia, `NULL` (em bancos de dados), `NaN` (no Python), símbolos como "—", "N/A", "?" e "#N/D", ou células com apenas espaços, que parecem vazias mas não são.

Por que acontecem

- **A pessoa não respondeu:** por privacidade ou desconforto (a renda é o exemplo clássico).
- **O dado não existe:** a data de cancelamento de quem ainda é cliente.
- **Falha de sistema:** erro na coleta, na integração ou numa atualização.
- **Campo opcional:** o formulário deixava em branco sem consequência.
- **Fluxo interrompido:** a pessoa abandonou o formulário no meio.

> **Entender o motivo do vazio decide o tratamento.**

Um vazio que significa "não existe" (cliente sem segundo telefone) é informação e pode ficar vazio. Um vazio por falha de sistema é perda e pode ser preenchido com cuidado. Se os vazios não são aleatórios (por exemplo, quem ganha mais deixa a renda em branco com mais frequência), qualquer preenchimento introduz viés.

Estratégias

ESTRATÉGIA	QUANDO USAR	RISCO
Manter vazio	O vazio tem significado ou a análise consegue ignorá-lo	Algumas contas usam só parte dos registros
Preencher com a mediana	Coluna numérica, especialmente com valores extremos	Cria muitos registros com o mesmo valor e reduz a variação
Preencher com a média	Coluna numérica sem valores extremos	Se houver extremos, puxa os vazios para um valor que não é típico
Preencher com a moda	Coluna categórica (a cidade mais frequente, por exemplo)	Aumenta artificialmente a categoria mais comum
Remover as linhas	Poucos vazios (menos de 5%) e sem padrão aparente	Perde informação das outras colunas e cria viés se os vazios não forem aleatórios
Excluir a coluna	Coluna quase toda vazia (acima de 40%)	Perde a variável inteira

Como referência prática: até cerca de 15% de vazios numa coluna costuma não comprometer a análise; preencher faz sentido quando os vazios são moderados (abaixo de 20%); acima de 40%, considere excluir a variável. Não existe estratégia universalmente certa: a escolha depende do contexto, do volume de dados e da pergunta.

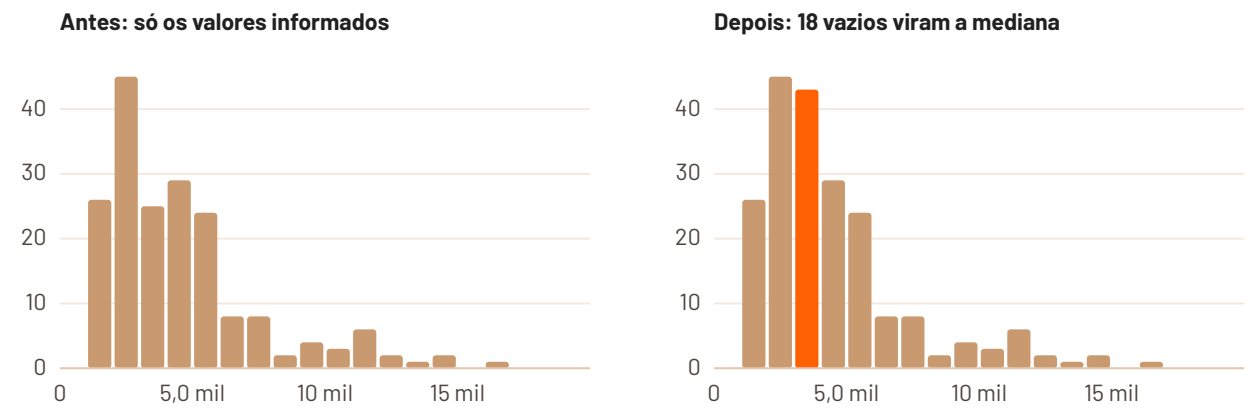


Figura 3.2 · Renda antes e depois de preencher os vazios com a mediana. A barra laranja cresce com clientes que passaram a ter exatamente o mesmo valor. A distribuição fica mais concentrada do que a realidade.

! CUIDADO

Preencher não é encontrar o valor verdadeiro

- Preencher muitos vazios com o mesmo valor reduz a variação dos dados e cria uma distribuição irreal.
- Se os vazios não são aleatórios, o preenchimento cria padrões falsos.
- Vazios sistemáticos podem indicar um problema na coleta que precisa ser corrigido na origem, e não escondido.
- Sempre compare o antes e o depois (média, mediana, variação) e documente a decisão. Uma boa prática é criar uma coluna que marca quais valores foram preenchidos.

3.4 Duplicatas

Duplicata é o mesmo registro (pessoa, produto, transação) aparecendo mais de uma vez. Acontece por importação repetida do mesmo arquivo, formulário enviado duas vezes, junção mal feita de fontes ou falha na integração.

Duplicatas inflam contagens e totais: um cliente que aparece três vezes infla a contagem em 200%. Elas também distorcem médias, criam padrões que não existem e enviesam modelos.

TIPO	COMO É	O QUE FAZER
Exata	Todos os campos iguais	Remover sem dúvida
Parcial	Mesma chave (o mesmo `id_cliente`) com algum campo diferente	Decidir qual versão fica: a mais recente ou a mais completa
Por erro humano	"Ana Silva" e "Ana da Silva", com o mesmo e-mail	Investigar e unificar com uma regra
Equivalentes	Uma compra registrada por item ou como total	Definir a regra de negócio antes de contar

E EXEMPLO

As duplicatas da base de clientes

A base começa com 210 linhas. Removendo as cópias exatas (todas as colunas iguais), saem 6 e ficam 204. Depois, olhando só a chave `id_cliente`, ainda há 4 clientes que aparecem duas vezes com algum dado diferente, como a data da última compra. Mantendo a versão mais recente de cada um, ficam 200 clientes, um por linha.

A ordem importa: primeiro as exatas, depois as parciais, e antes de remover as parciais, ordene para que a versão que você quer manter venha primeiro.

3.5 Texto inconsistente

Para o computador, "Recife", "recife", "RECIFE", " Recife" (com espaço) e "Recfie" (com erro de digitação) são cinco cidades diferentes. Uma contagem por cidade fica errada e um gráfico mostra barras que não existem.

A padronização tem uma ordem que funciona bem:

1. **Tirar espaços** no começo, no fim e duplicados no meio.
2. **Uniformizar maiúsculas e minúsculas** (por exemplo, só a primeira letra de cada palavra maiúscula).
3. **Corrigir com um dicionário** o que sobrou: erros de digitação e variações ("Recfie" → "Recife", "Jaboatao dos Guararapes" → "Jaboatão dos Guararapes").
4. **Contar de novo** para confirmar: as 15 grafias da base viram 5 cidades.

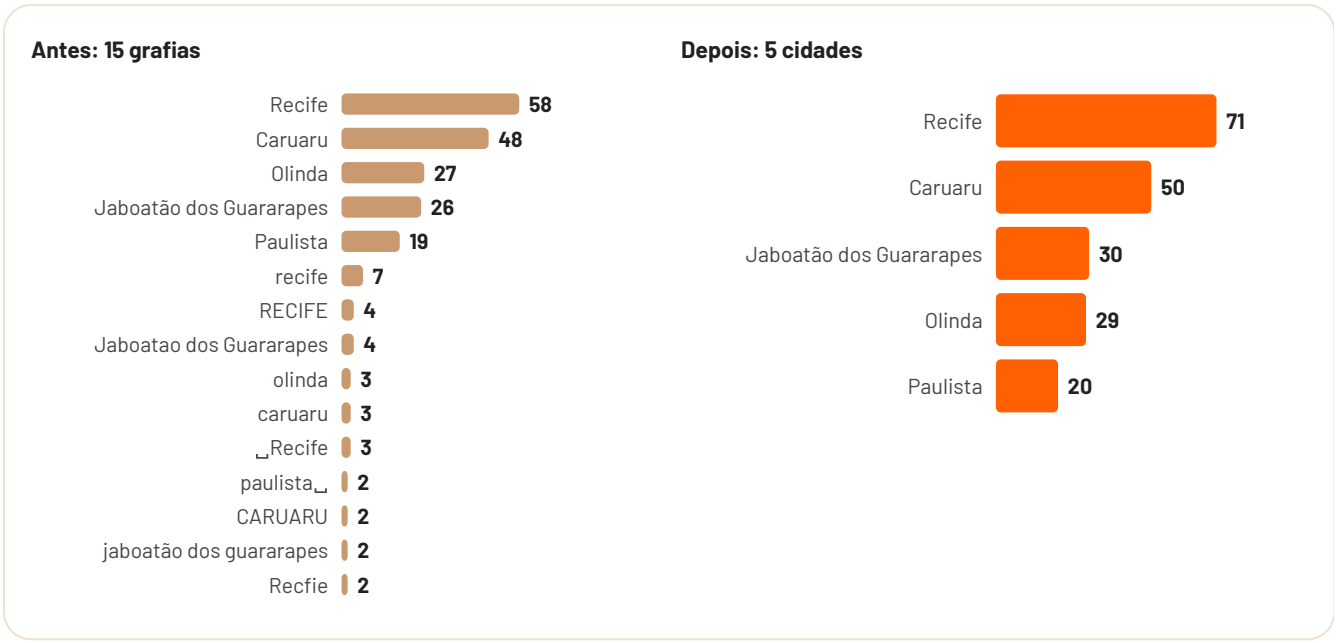


Figura 3.3 · Contagem por cidade antes e depois da padronização. As grafias diferentes se juntam e a contagem real aparece. O símbolo ␣ marca um espaço invisível.

3.6 O log de limpeza

Toda decisão de limpeza deve ser registrada. O log responde a três perguntas para cada passo: o que foi feito, por que foi feito dessa forma e qual seria o risco de não fazer. Ele garante que outra pessoa entenda e repita a limpeza, e é exigido no Projeto Integrador.

O QUE FOI FEITO	POR QUÊ	RISCO DE NÃO FAZER
Removi 6 linhas duplicadas exatas	Eram cópias idênticas, provavelmente importadas duas vezes	Contagens e totais inflados
Removi 4 repetidos por `id_cliente`, mantendo a compra mais recente	O mesmo cliente com dois cadastros	O cliente contado duas vezes
Padronizei `cidade` de 15 para 5 valores	Cada grafia contava como uma cidade diferente	Contagem e gráficos por cidade errados
Preenchi os vazios de `renda_mensal` com a mediana	Coluna numérica com poucos vazios e valores extremos	Cálculos usariam só parte dos clientes
Excluí a coluna `telefone_2`	63% de vazios	Conclusões apoiadas numa coluna quase vazia

Uma regra de ouro: guarde sempre a base original intacta. Limpe numa cópia.

X NO EXCEL, SÓ COM CLIQUES

A limpeza do Encontro 3 sem fórmulas

1. **Conte os vazios.** Na seta do filtro de uma coluna, deixe marcado só **(Vazias)**. A barra de status mostra quantos registros foram encontrados (por exemplo, "18 de 210 registros encontrados" para a renda). Repita para cada coluna e depois use **Limpar Filtro**.
2. **Realce os vazios.** Selecione a tabela e use **Página Inicial › Formatação Condicional › Nova Regra › Formatar apenas células que contenham › Vazias**, escolhendo uma cor. O mapa da base aparece na tela.
3. **Remova as cópias exatas. Dados › Remover Duplicatas**, com todas as colunas marcadas. O Excel informa quantas saíram e quantas ficaram.
4. **Remova os repetidos por chave.** Ordene `data_ultima_compra` da mais nova para a mais antiga e use **Remover Duplicatas** marcando só `id_cliente`. O Excel mantém a primeira ocorrência, que agora é a mais recente.
5. **Padronize o texto. Página Inicial › Localizar e Selecionar › Substituir**, com a opção **Coincidir conteúdo da célula inteira** marcada, trocando uma grafia de cada vez. Para espaços invisíveis, digite o espaço no campo Localizar.
6. **Confira.** Uma Tabela Dinâmica com `cidade` em Linhas lista todas as grafias que ainda existem.
7. **Preencha vazios de uma vez.** Filtre a coluna por (Vazias), selecione as células vazias visíveis, digite o valor (a mediana da aula) e pressione `Ctrl` + `Enter`: todas recebem o valor juntas.
8. **Exclua a coluna quase vazia.** Clique com o botão direito na letra da coluna e escolha **Excluir**.

Σ POR TRÁS DA CONTA

Como a mediana é encontrada

Coloque os valores informados em ordem, do menor para o maior, e pegue o do meio. Se a quantidade for par, a mediana é o ponto entre os dois do meio. Por isso ela não se abala quando um cliente tem renda muito alta: ele só ocupa a última posição da fila.

P NO PROJETO

Com a base do grupo, façam o raio-X e registrem o diagnóstico na aba 0_Documentação: vazios por coluna, duplicatas e problemas de texto. A limpeza vai para a aba 2_Base_Limpa, com o log ao lado. O Laboratório do projeto faz o raio-X e monta o log automaticamente; o grupo escreve o porquê e o risco de cada decisão.

Para revisar

- Qualidade tem cinco dimensões: precisão, completude, consistência, atualidade e unicidade.
- Diagnostique antes de mexer. O mapa de vazios mostra o padrão da base de relance.
- O motivo do vazio decide o tratamento. Mediana para números com extremos, moda para categorias, excluir colunas com mais de 40% de vazios.
- Preencher reduz a variação; registre e compare o antes e o depois.
- Remova primeiro as duplicatas exatas, depois as parciais, escolhendo a versão que fica.
- Padronize texto na ordem: espaços, caixa, dicionário, contagem final.
- Cada decisão vai para o log: o quê, por quê e o risco de não fazer.

Exercícios

1. Para cada problema, diga a dimensão da qualidade afetada: (a) data de cadastro em 2027; (b) cliente com dois cadastros; (c) "Caruaru" e "CARUARU"; (d) renda vazia; (e) idade de −3 anos.
2. A coluna `data_cancelamento` está vazia em 85% das linhas. Você excluiria a coluna? Justifique.
3. A coluna `renda_mensal` tem 9% de vazios e alguns clientes com renda muito alta. Que estratégia você escolheria e por quê?
4. Um cliente aparece duas vezes com o mesmo `id_cliente`, mas com datas de última compra diferentes (março e agosto). Qual versão você manteria e como faria isso numa planilha?
5. Por que preencher todos os vazios de uma coluna com a mesma mediana pode atrapalhar uma análise de variação?
6. Escreva a linha do log para a decisão: "padronizei a coluna canal, que tinha App, APP, app, Whatsapp e WhatsApp".

ENCONTRO 4

4 LIMPEZA II E PREPARAÇÃO

AO FINAL DESTE CAPÍTULO VOCÊ VAI SABER

- encontrar inconsistências entre colunas e datas que não fecham;
- diferenciar valores impossíveis, suspeitos e raros;
- detectar outliers pelo método IQR e decidir, com contexto, o que fazer com eles;
- criar faixas, mudar a escala de variáveis e decompor datas;
- justificar cada coluna nova pela pergunta que ela ajuda a responder.

O Capítulo 3 tratou vazios, repetidos e texto. Este capítulo trata da segunda metade da limpeza (números que não fecham, datas impossíveis, valores fora da curva) e da preparação: as colunas novas de que a análise vai precisar. O exemplo é a base de uma loja online, `ecommerce_encontro4.csv`, com 308 linhas (300 pedidos depois de remover 8 cópias).

4.1 Quando a conta da própria base não fecha

Algumas colunas são calculadas a partir de outras. O dicionário da base de pedidos define:

> **total = quantidade × preço − desconto + frete**

Refazer essa conta para cada pedido e comparar com o total informado revela inconsistências. Na base de pedidos, entre os pedidos com todos os componentes preenchidos, 14 têm o total diferente da regra: 12 por erro na conta e 2 porque o preço unitário foi registrado 100 vezes maior (um livro de R$ 53,73 aparece como R$ 5.373,00).

Quando a regra é clara e as parcelas estão certas, corrija o total pela regra. Quando a diferença é grande demais para ser arredondamento, investigue a parcela suspeita antes de corrigir.

4.2 Datas que não fecham

Datas trazem três tipos de problema:

- **Formato:** "01/03/2023" e "2023-03-01" na mesma coluna, ou datas guardadas como texto.
- **Data inválida:** mês 13, dia 31 de fevereiro, data no futuro.
- **Ordem:** a data final antes da inicial, como uma entrega registrada antes do pedido.

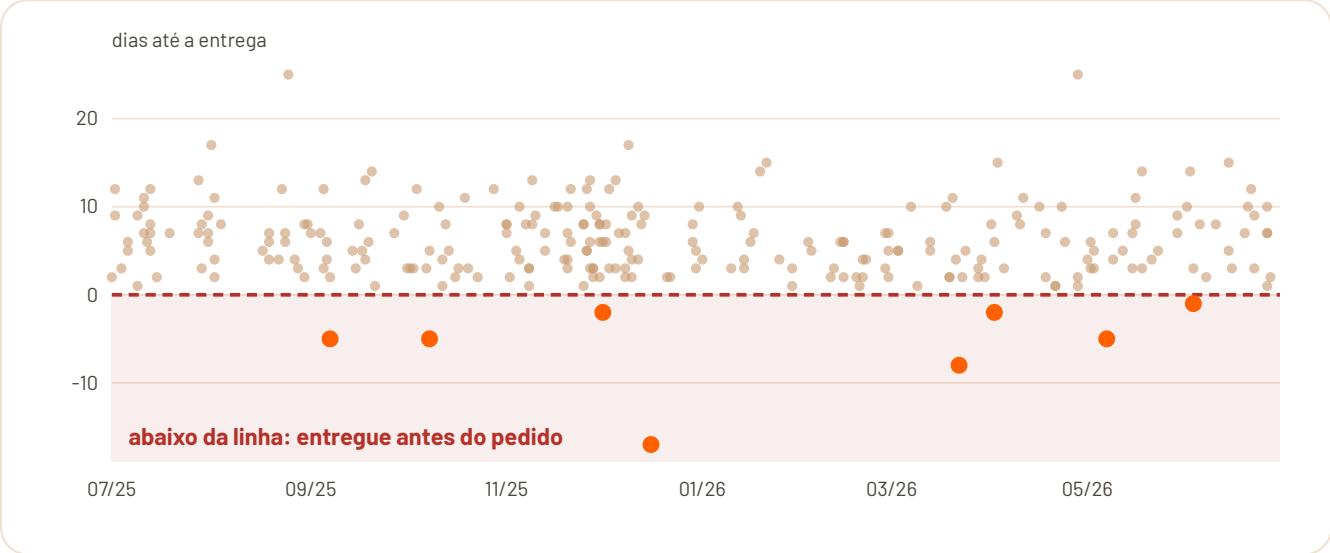


Figura 4.1 · Cada ponto é um pedido: na horizontal, a data do pedido; na vertical, quantos dias levou até a entrega. Os pontos laranja, abaixo do zero, foram "entregues antes de serem comprados".

Na base de pedidos, 8 pedidos têm a entrega antes do pedido. Três estratégias são possíveis, cada uma com um custo:

ESTRATÉGIA	QUANDO FAZ SENTIDO	CUSTO
Inverter as datas	Há indício de que as colunas foram trocadas na digitação	Se não foi troca, cria um prazo falso
Deixar a data final vazia	Não há como saber a data certa	O pedido sai das análises de prazo
Remover o pedido	O registro inteiro parece não confiável	Perde as outras informações do pedido

! CUIDADO

Nem todo vazio é erro

41 pedidos não têm data de entrega. Olhando a coluna `status`, todos estão "em trânsito" ou "cancelados": o vazio é legítimo, porque a entrega ainda não aconteceu ou nunca vai acontecer. Preencher essas datas seria inventar entregas.

4.3 Impossível, suspeito ou raro

Antes de falar de outliers, vale separar três situações que parecem iguais, mas pedem tratamentos diferentes.

SITUAÇÃO	O QUE É	EXEMPLOS	O QUE FAZER
Impossível	Viola uma regra lógica ou física	Idade –3; nota 7 numa escala de 1 a 5; 400 horas trabalhadas numa semana de 168	É sempre erro: corrigir se souber o valor, senão deixar vazio
Suspeito	Possível, mas improvável no contexto	Livro vendido por R$ 5.373,00	Investigar antes de mexer (aqui, a vírgula estava no lugar errado)
Raro, mas real	Extremo e verdadeiro	Notebook de R$ 8.999,00; cliente de 98 anos	Manter. Apagar esconderia uma venda ou um cliente real

4.4 Outliers: fora da curva

Outlier é um valor muito distante dos demais. Ele pode ser erro (de medição, de digitação, de sistema) ou um caso legítimo e excepcional. Em qualquer caso, merece atenção, porque:

- **distorce a média:** num grupo com rendas entre R$ 3.000 e R$ 8.000, uma renda de R$ 500.000 leva a média para longe de qualquer cliente real;
- **aumenta a variação:** os dados parecem mais heterogêneos do que são;
- **inventa relações:** um único ponto extremo pode criar uma correlação que não existe no resto dos dados (veja o Capítulo 6).

O método IQR

O método mais usado para marcar outliers se baseia nos quartis, os valores que dividem os dados ordenados em quatro partes iguais.

1. **Q1** (primeiro quartil): 25% dos valores ficam abaixo dele.
2. **Q3** (terceiro quartil): 75% dos valores ficam abaixo dele.
3. **IQR** (intervalo interquartil) = Q3 – Q1: a largura dos 50% do meio.
4. **Cercas:** limite inferior = Q1 – 1,5 × IQR; limite superior = Q3 + 1,5 × IQR. O que passa da cerca é marcado como outlier.

O fator 1,5 é o padrão. Com 3, a cerca fica mais larga e marca só os extremos mais fortes. Com 1, fica mais apertada e marca mais valores.

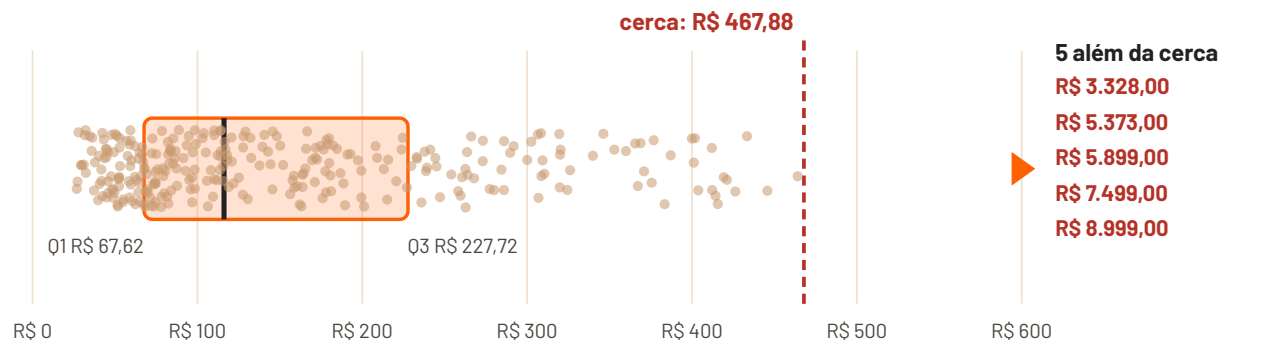


Figura 4.2 · Preços dos pedidos: a caixa contém os 50% do meio e a linha vermelha tracejada é a cerca superior. Cinco preços passam dela; os valores estão listados à direita, fora da escala.

E EXEMPLO

Os cinco preços além da cerca

Na base de pedidos, Q1 = R$ 67,62, Q3 = R$ 227,72 e a cerca superior fica em R$ 467,88. Cinco preços passam dela:

PRODUTO	PREÇO	DECISÃO
Notebook Gamer	R$ 8.999,00	Real: manter
Smart TV 65"	R$ 7.499,00	Real: manter
Celular top de linha	R$ 5.899,00	Real: manter
Biografia (livro)	R$ 5.373,00	Erro: era R$ 53,73
Protetor solar	R$ 3.328,00	Erro: era R$ 33,28

A estatística marcou os cinco. Quem decidiu foi o contexto: o produto e a categoria mostram quais preços fazem sentido.

Remover, investigar ou destacar

- **Remover** quando há certeza de erro: idade de 500 anos, salário com zeros a mais.
- **Investigar** quando pode ser legítimo, mas é excepcional: consulte quem conhece o negócio, a documentação e a fonte.
- **Destacar** quando é raro, real e importante (fraude, cliente VIP, falha de sistema): não remova; analise esses casos à parte.

Em muitos casos, a melhor saída é fazer a análise duas vezes, com e sem os outliers, e comparar.

4.5 Transformar números em faixas

Transformar é modificar os dados de forma sistemática para torná-los mais adequados à análise. Não é manipulação: é preparação. A primeira transformação é a **categorização**: trocar um número por uma faixa (baixo, médio, alto). Faixas facilitam comparar grupos e comunicar resultados.

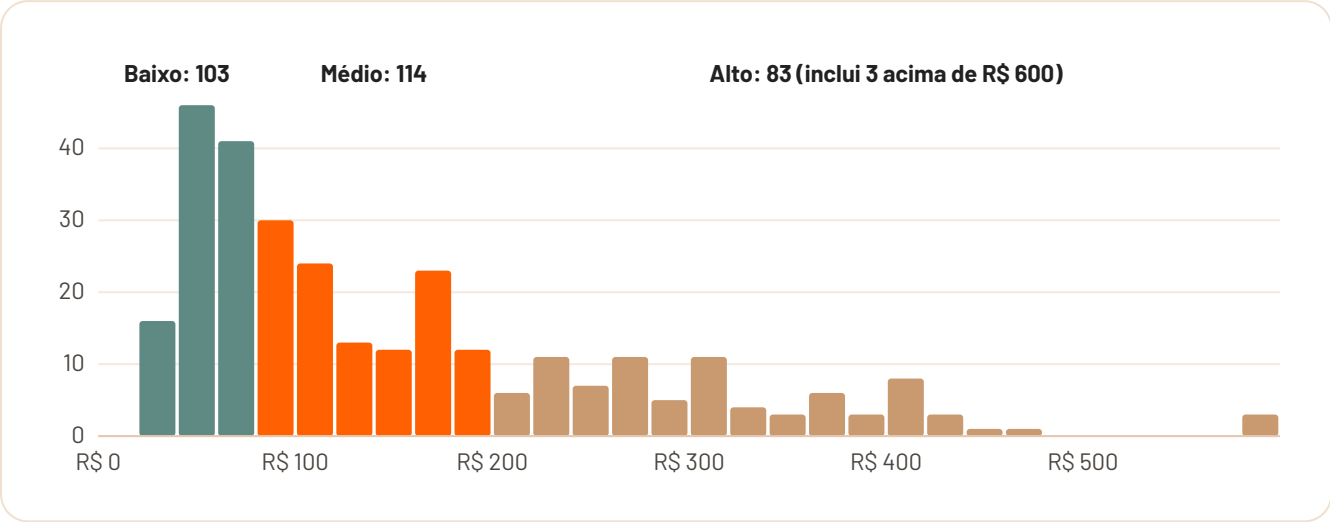


Figura 4.3 · Preços com limites em R$ 80 e R$ 200. As três faixas ficam com tamanhos parecidos, o que permite comparar os grupos.

Os limites podem vir de duas fontes: da **distribuição** (por exemplo, dividir em três grupos com quantidades parecidas) ou do **negócio** (o frete grátis começa em R$ 200, por exemplo). O cuidado é não criar faixas desequilibradas: com limites de R$ 25 e R$ 1.000, quase todos os pedidos caem na faixa do meio, e a comparação perde o sentido.

4.6 Normalizar e padronizar

Quando duas variáveis estão em escalas muito diferentes, a maior "engole" a menor. A quantidade de itens vai de 1 a 5; o preço vai de R$ 20 a R$ 9.000. Mudar a escala permite comparar as duas de forma justa e é exigido por vários algoritmos de aprendizado de máquina.

	NORMALIZAÇÃO (MÍNIMO E MÁXIMO)	PADRONIZAÇÃO (ESCORE Z)
Resultado	Valores de 0 a 1: o menor vira 0 e o maior vira 1	Média 0 e desvio padrão 1; a maioria fica entre −3 e +3
Lê-se como	"Onde o valor está entre o menor e o maior"	"Quantos desvios o valor está acima ou abaixo da média"
Cuidado	Um único outlier muda o mínimo ou o máximo e espreme todo o resto	Pressupõe que média e desvio representam bem a variável
Usar quando	Precisa de uma escala fixa de 0 a 1	Quer comparar variáveis diferentes ou há valores extremos

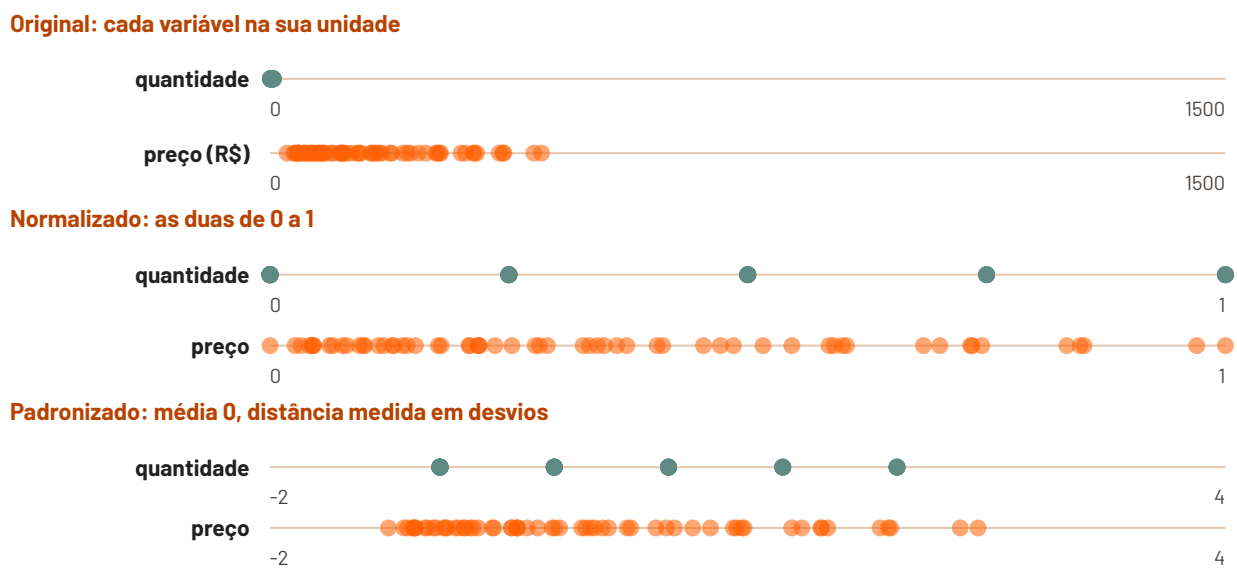


Figura 4.4 · As mesmas quantidades (verde) e preços (laranja) em três escalas. No original, as quantidades se espremem no início do eixo. Normalizadas ou padronizadas, as duas variáveis ficam comparáveis.

Σ POR TRÁS DA CONTA

As duas contas, em palavras

Normalizar: subtraia o menor valor e divida pela distância entre o maior e o menor. Uma quantidade 3, numa coluna que vai de 1 a 5, vira (3 – 1) ÷ (5 – 1) = 0,5: está no meio do caminho.

Padronizar: subtraia a média e divida pelo desvio padrão. Se a média de preços é R$ 200 com desvio de R$ 100, um preço de R$ 350 vira (350 – 200) ÷ 100 = 1,5: está um desvio e meio acima da média.

Há ainda a transformação **logarítmica**, que comprime valores muito grandes (útil para renda e preços com cauda longa). Ela fica como referência para estudos futuros.

4.7 Uma data guarda várias informações

De uma única data saem várias colunas, e cada uma responde a uma pergunta diferente:

COLUNA NOVA	EXEMPLO PARA 14/11/2025	PERGUNTA QUE AJUDA A RESPONDER
Ano	2025	Há tendência de longo prazo?
Mês	11 (novembro)	Há sazonalidade? A Black Friday pesa?
Dia da semana	sexta-feira	Fim de semana vende diferente dos dias úteis?
Trimestre	4º	Como foi cada período fiscal?
Dias entre duas datas	pedido 14/11, entrega 21/11: 7 dias	O prazo de entrega mudou? Prazo afeta a avaliação?

4.8 Colunas derivadas com propósito

Toda coluna nova precisa de um motivo. Antes de criar, responda: que pergunta ou hipótese ela ajuda a responder? Sem ela, a análise ficaria impossível, incompleta ou menos interpretável?

COLUNA DERIVADA	DE ONDE VEM	REGRA	PARA QUÊ
`faixa_preco`	`preco_unitario`	Baixo: menos de R$ 80; Médio: de R$ 80 a menos de R$ 200; Alto: R$ 200 ou mais	Comparar avaliação por faixa de preço (menos interpretável sem ela)
`mes_pedido`	`data_pedido`	Mês da data	Ver a sazonalidade (impossível sem ela)
`dia_semana_pedido`	`data_pedido`	Dia da semana da data	Comparar dias úteis e fim de semana (impossível sem ela)
`prazo_entrega_dias`	`data_pedido`, `data_entrega`	Dias entre as duas datas	Testar se o prazo afeta a avaliação (impossível sem ela)

Com a limpeza das duas partes e as colunas derivadas, a base está **preparada**: vazios tratados, duplicatas removidas, outliers avaliados e variáveis prontas para a exploração.

X NO EXCEL, SÓ COM CLIQUES

Encontrar e marcar sem fórmulas

1. **Veja os extremos.** Na seta do filtro de `preco_unitario`, escolha **Classificar do Maior para o Menor**. Os primeiros da lista são os candidatos a outlier.
2. **Realce o que passa da cerca.** Selecione a coluna de preço e use **Página Inicial › Formatação Condicional › Realçar Regras das Células › É Maior do que**, digitando o valor da cerca que a aula calculou.
3. **Investigue caso a caso.** Olhe produto e categoria de cada preço realçado e decida: erro ou extremo real.
4. **Ache datas trocadas.** No filtro de `id_pedido`, marque só os pedidos que a aula apontou e compare as duas datas de cada um.
5. **Entenda os vazios.** Filtre `data_entrega` por (Vazias) e olhe a coluna `status`.
6. **Cole a base preparada.** Numa aba nova, clique em A1 e cole o que a aula copiou. As colunas derivadas já vêm prontas.
7. **Confira as faixas. Inserir › Tabela Dinâmica**, com `faixa_preco` em Linhas e de novo em Valores (contagem).

Σ POR TRÁS DA CONTA

Como a cerca é calculada

A aula coloca os preços em ordem e acha Q1 (o preço que deixa 25% abaixo) e Q3 (o que deixa 75% abaixo). A distância entre eles é o IQR, R$ 160,10 nesta base. A cerca superior é Q3 mais uma vez e meia essa distância. Tudo o que passa dela é marcado para você investigar.

P NO PROJETO

Na base do grupo, tratem as datas e os valores impossíveis e criem pelo menos três colunas derivadas na aba 3_Preparação. Para cada uma, registrem a regra, a coluna original e a pergunta que ela ajuda a responder. Os outliers vão para a aba 4_Outliers_e_Correlação, com a decisão justificada em termos de negócio.

Para revisar

- Colunas calculadas devem bater com a regra do dicionário. Refaça a conta para encontrar inconsistências.
- Datas podem ter problema de formato, de validade e de ordem. Vazio legítimo (entrega que ainda não aconteceu) não é erro.
- Impossível é sempre erro; suspeito pede investigação; raro e real deve ser mantido.
- IQR = Q3 − Q1. Cercas em Q1 − 1,5 × IQR e Q3 + 1,5 × IQR. A estatística marca; o contexto decide.
- Faixas facilitam comparar grupos, desde que os limites façam sentido e não criem grupos vazios.
- Normalizar leva os valores para 0 a 1; padronizar mede a distância da média em desvios.
- Toda coluna derivada precisa de uma pergunta que a justifique.

Exercícios

1. Classifique como impossível, suspeito ou raro: (a) desconto de 120% num pedido; (b) pedido com 50 unidades de um mesmo livro; (c) frete de R$ 0,00; (d) data de nascimento em 1890 num cadastro de 2025.
2. Numa coluna de tempos de atendimento, Q1 = 8 minutos e Q3 = 20 minutos. Calcule o IQR e as cercas. Um atendimento de 45 minutos é outlier?
3. Por que a decisão sobre um outlier deve usar argumentos de negócio, e não só a cerca?
4. Você quer saber se as vendas do fim de semana são diferentes das dos dias úteis, mas a base só tem a coluna `data_pedido`. O que você cria e por quê?
5. Uma colega criou faixas de renda com limites em R$ 500 e R$ 50.000. O que provavelmente aconteceu com os grupos e como corrigir?
6. Uma variável vai de 10 a 60. Normalize os valores 10, 35 e 60.

ENCONTRO 5

5 EXPLORAÇÃO DE DADOS

AO FINAL DESTE CAPÍTULO VOCÊ VAI SABER

- explicar o que é análise exploratória e como ela orienta o resto do trabalho;
- ler histogramas, boxplots, gráficos de barras, dispersão e séries no tempo;
- comparar grupos e cruzar duas categorias numa tabela de contingência;
- escolher o gráfico adequado para cada pergunta;
- transformar o que viu em hipóteses para testar.

A análise exploratória de dados (EDA, do inglês *exploratory data analysis*) é olhar os dados com curiosidade antes de tirar conclusões: como cada variável se comporta, onde estão os padrões, o que está fora do lugar e que perguntas novas surgem. A base deste capítulo é a de clientes do Encontro 3 já limpa (`clientes_encontro5_limpa.csv`), com 200 clientes.

5.1 O que é explorar

A EDA reduz incertezas, revela comportamentos que não se veem na tabela, aponta insights iniciais e prepara o terreno para análises mais formais. Ela segue um ciclo:

1. **Observar** a base e cada variável;
2. **descrever** o que é típico e o que varia;
3. **comparar** grupos;
4. **investigar** o que chama atenção;
5. **formular hipóteses** para testar depois.

Seis perguntas guiam a exploração: o que é típico? Quem são os extremos? Existem grupos distintos? Como as variáveis se relacionam? Há padrões no tempo? Quem são, afinal, meus clientes?

! CUIDADO

A EDA sugere; não prova

O que aparece na exploração são pistas. Um padrão visto num gráfico vira uma hipótese, que precisa ser testada com cuidado no Capítulo 6 e no Capítulo 7.

5.2 Uma variável numérica: a distribuição

A **distribuição** de uma variável é o jeito como os valores se espalham: onde se concentram, até onde vão, se há lacunas. O gráfico mais usado para vê-la é o **histograma**. Ele divide a faixa de valores em intervalos de mesma largura (as barras) e conta quantos registros caem em cada um.

Ao olhar um histograma, procure:

- **formato:** simétrico, assimétrico para um lado, com dois picos;
- **centro:** onde está o pico, onde fica a maioria;
- **espalhamento:** se os valores estão concentrados ou espalhados;
- **caudas e extremos:** valores isolados longe do resto;
- **lacunas:** intervalos vazios que podem indicar grupos diferentes ou erro.

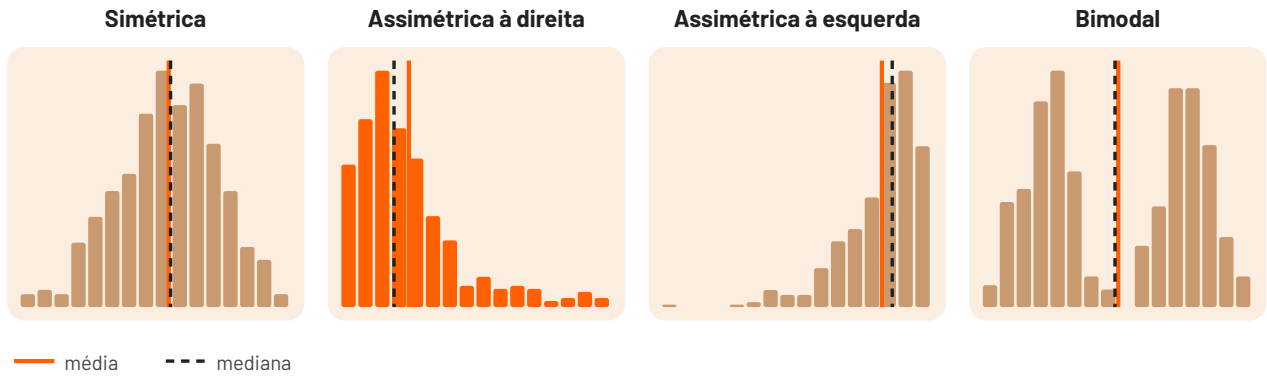


Figura 5.1 · Quatro formatos comuns. Na assimetria à direita (cauda longa para valores altos), a média fica à direita da mediana; na assimetria à esquerda, o contrário. Dois picos sugerem dois grupos misturados.

Renda e preços costumam ser assimétricos à direita: muita gente com valores moderados e poucos com valores muito altos. É o caso da renda dos nossos clientes.

A média da renda é R$ 5.060,67 e a mediana, R$ 3.889,40. A média está acima porque alguns clientes de renda muito alta a puxam para cima. A mediana descreve melhor o cliente típico. Comparar as duas é o jeito mais rápido de detectar assimetria.

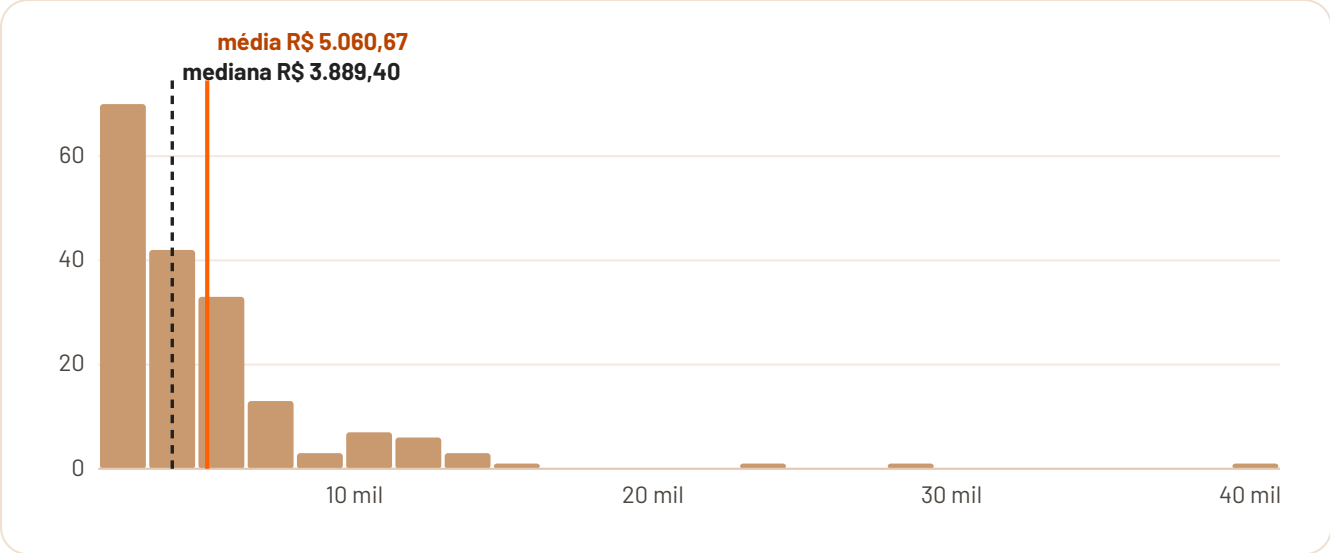


Figura 5.2 · Renda mensal dos clientes. A cauda longa à direita puxa a média para cima da mediana.

> ! CUIDADO
>
> **O número de barras muda a história**
>
> Com poucas barras, o histograma esconde detalhes (dois picos podem virar um). Com barras demais, ele vira ruído. Experimente alguns tamanhos antes de concluir sobre o formato.

5.3 Boxplot sem mistério

O **boxplot** (gráfico de caixa) resume uma variável inteira num desenho só, usando os quartis que você viu no Capítulo 4.

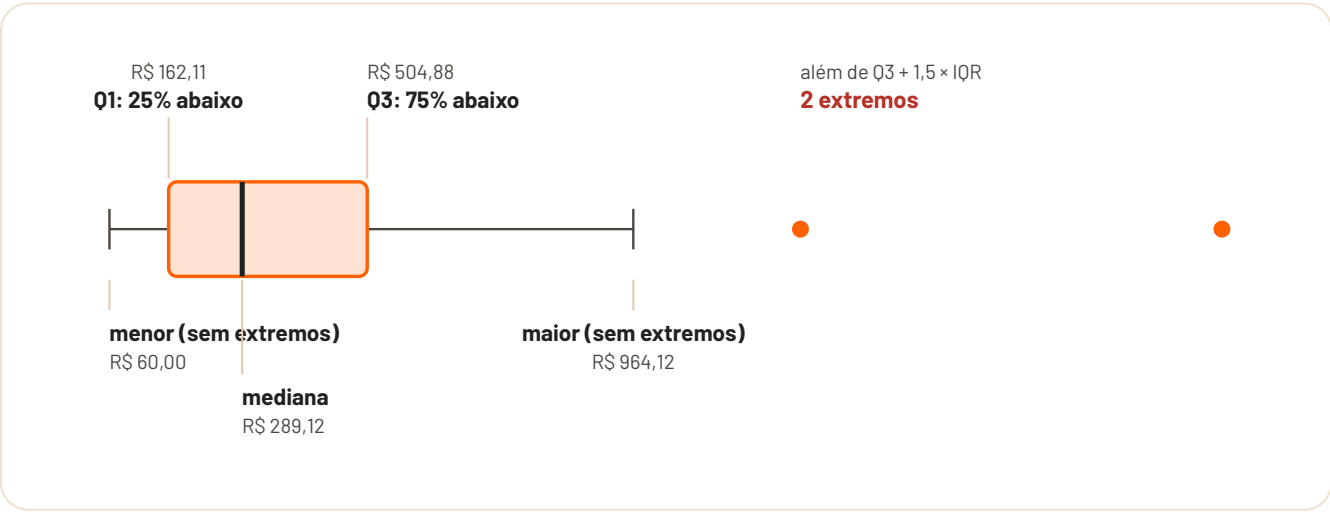


Figura 5.3 · Anatomia do boxplot do gasto mensal. A caixa vai de Q1 a Q3 (os 50% do meio), a linha dentro dela é a mediana, os bigodes vão até o maior e o menor valor dentro das cercas, e os pontos isolados são os extremos.

O boxplot mostra de uma vez o típico (a mediana), a variação (a largura da caixa), a assimetria (se a mediana está mais perto de um lado) e os extremos (os pontos). Ele brilha quando colocamos vários lado a lado para comparar grupos.

5.4 Uma variável categórica: frequências

Para categorias, o resumo é a **contagem** e o **percentual** de cada uma, mostrados num gráfico de barras. Ordene as barras da maior para a menor, a não ser que a categoria tenha ordem própria (como os planos Básico, Plus e Premium).

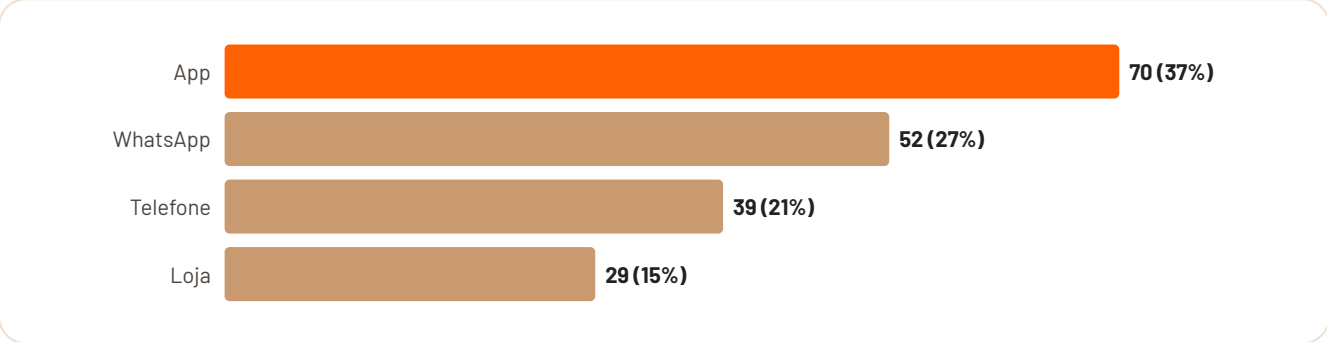


Figura 5.4 · Clientes por canal de atendimento. O canal mais usado (a moda) está em destaque.

O canal mais frequente é App, com 70 clientes. Repare que o total é menor que 200: alguns clientes não têm canal registrado. Percentuais devem deixar claro sobre qual total foram calculados.

5.5 Comparar grupos

Comparar é uma das perguntas mais comuns: os clientes Premium gastam mais? A satisfação muda por canal? A forma mais completa é colocar um boxplot por grupo lado a lado.

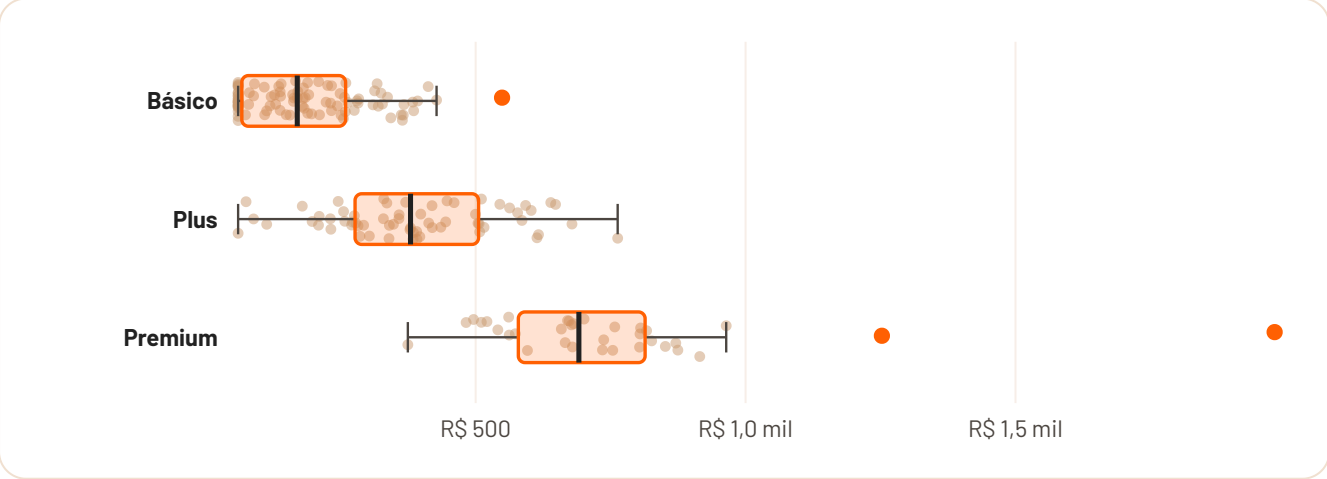


Figura 5.5 · Gasto mensal por plano. Cada caixa mostra o típico e a variação de um grupo; os pontos são os clientes.

PLANO	CLIENTES	GASTO MÉDIO	GASTO MEDIANO
Básico	101	R$ 185,94	R$ 169,55
Plus	63	R$ 386,21	R$ 379,37
Premium	36	R$ 746,27	R$ 691,22

O gasto cresce do Básico ao Premium e as caixas quase não se sobrepõem: a diferença entre os grupos é grande em relação à variação dentro de cada um. Quando as caixas se sobrepõem muito, a diferença entre médias pode ser só acaso.

! CUIDADO

Grupos pequenos enganam

Uma média calculada com 5 clientes oscila muito; com 100, é estável. Sempre mostre quantos registros há em cada grupo junto com a média.

5.6 Duas variáveis numéricas: a dispersão

O **gráfico de dispersão** coloca uma variável em cada eixo; cada ponto é um registro. Ele responde: quando uma sobe, a outra sobe também?

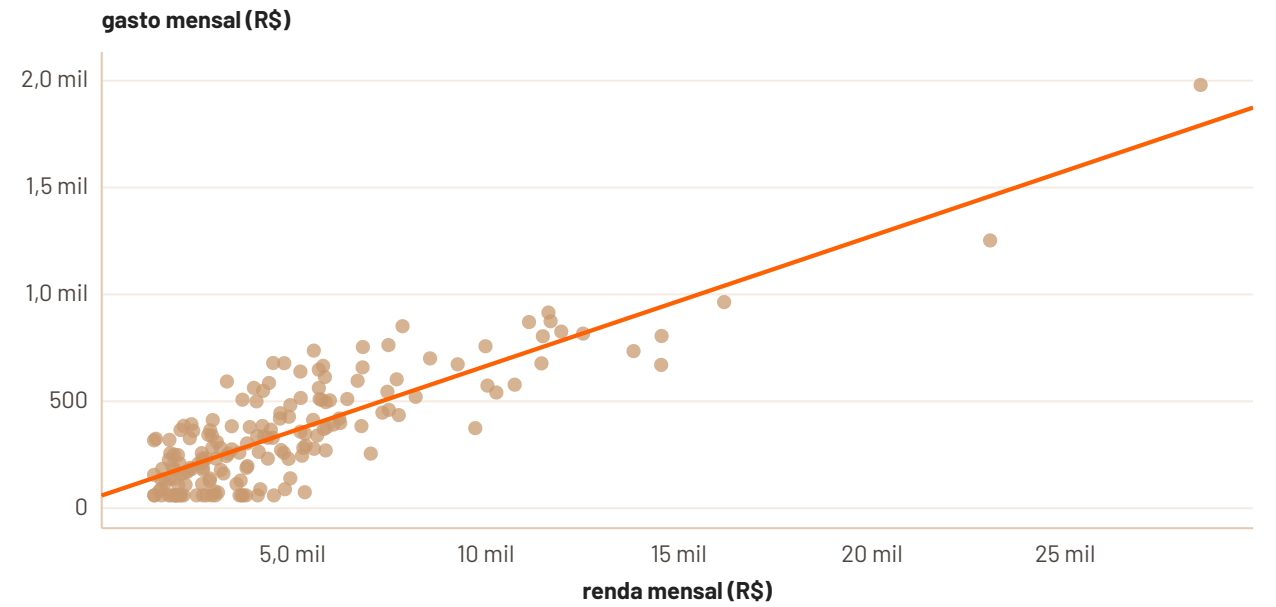


Figura 5.6 · Renda e gasto mensal dos clientes. A nuvem sobe da esquerda para a direita: quem ganha mais tende a gastar mais.

Ao ler uma dispersão, procure a **direção** (sobe, desce ou nenhuma), a **forma** (reta ou curva), a **força** (pontos próximos de uma linha ou espalhados), **grupos** separados e pontos **extremos** que fogem do padrão. A medida numérica dessa relação é a correlação, tema do Capítulo 6.

5.7 Duas variáveis categóricas: a tabela de contingência

Para cruzar duas categorias, use uma **tabela de contingência**: uma categoria nas linhas, outra nas colunas e a contagem em cada célula.

CANAL	BÁSICO	PLUS	PREMIUM	TOTAL
App	31	28	11	**70**
WhatsApp	27	15	10	**52**
Telefone	22	9	8	**39**
Loja	16	7	6	**29**
Total	**96**	**59**	**35**	**190**

Clientes por canal e plano (190 clientes com canal registrado).

Em quantidade, a tabela mostra onde estão os clientes, mas engana na comparação: o App tem mais clientes Premium simplesmente porque tem mais clientes. Para comparar os canais de forma justa, use o **percentual por linha**: em cada canal, que fração está em cada plano.

CANAL	BÁSICO	PLUS	PREMIUM	TOTAL
App	44%	40%	16%	100%
WhatsApp	52%	29%	19%	100%
Telefone	56%	23%	21%	100%
Loja	55%	24%	21%	100%

Percentual por linha: cada canal soma 100%.

Agora a leitura muda: a fatia de clientes Premium vai de 16% no canal App a 21% na Loja. As diferenças entre canais são pequenas.

5.8 Padrões no tempo

Quando a variável é medida ao longo do tempo, o gráfico natural é o de **linha**, com o tempo no eixo horizontal. Nele aparecem duas coisas que costumam vir misturadas:

- **tendência:** o movimento de longo prazo (crescimento, queda, estabilidade);
- **sazonalidade:** um padrão que se repete em períodos fixos (picos todo fim de ano, quedas todo começo de ano).

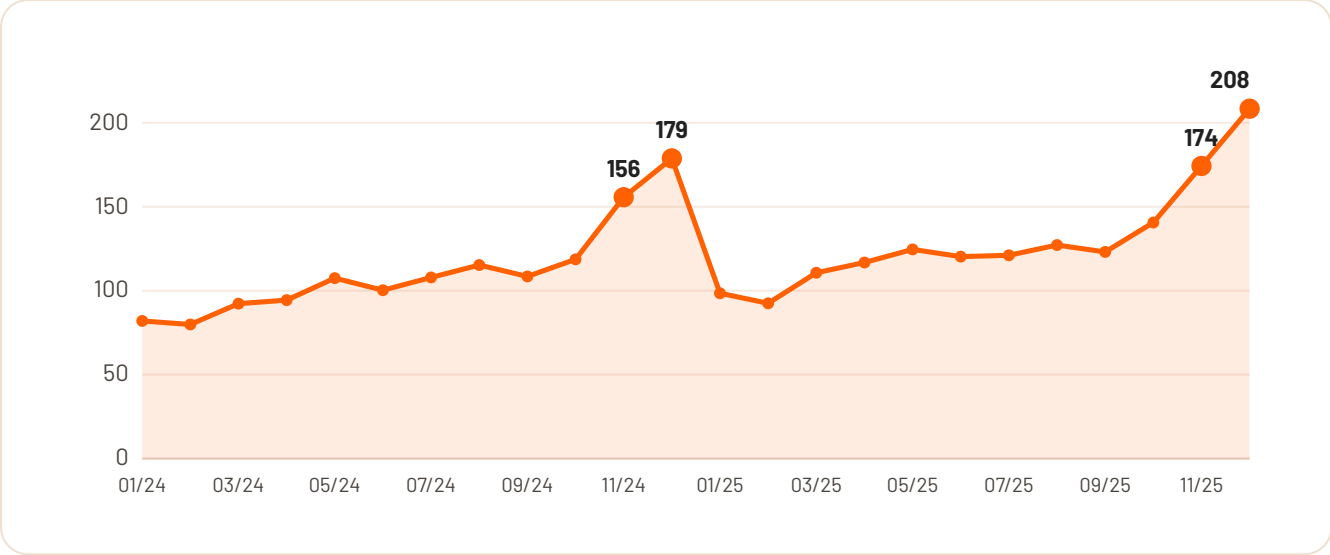


Figura 5.7 · Faturamento mensal de uma loja em dois anos, em milhares de reais (dados de exemplo). A linha sobe aos poucos (tendência) e tem picos em novembro e dezembro de cada ano (sazonalidade).

Para separar uma da outra, compare cada mês com o mesmo mês do ano anterior: novembro com novembro. Comparar novembro com outubro mistura o efeito da Black Friday com o crescimento da loja.

5.9 Escolher o gráfico certo

PERGUNTA	GRÁFICO
Como uma variável numérica se distribui?	Histograma
Qual o típico, a variação e os extremos?	Boxplot
Quantos há em cada categoria?	Barras (horizontais, se os nomes forem longos)
Os grupos são diferentes?	Boxplots lado a lado ou barras com a média e o tamanho do grupo
Duas variáveis numéricas andam juntas?	Dispersão
Duas categorias se combinam de forma diferente?	Tabela de contingência com percentual por linha
Como evoluiu no tempo?	Linha

Gráfico de pizza só funciona com poucas categorias e quando a pergunta é sobre partes de um todo. Na dúvida, barras comunicam melhor.

5.10 Da exploração às hipóteses

O resultado da EDA é uma lista de hipóteses, cada uma apoiada no que você viu. Exemplos com a base de clientes:

- "Clientes Premium gastam mais que os do Básico" (boxplot por plano);
- "Quem tem renda maior gasta mais" (dispersão renda × gasto);
- "Canais digitais têm satisfação diferente dos tradicionais" (comparação por canal);
- "A renda aumenta com a idade até certo ponto" (dispersão idade × renda).

Três cuidados evitam interpretações erradas: correlação não é causalidade; poucos dados enganam; médias puxadas por extremos enganam. Os três voltam no próximo capítulo.

Checklist de EDA

1. **Distribuição** de cada variável importante.
2. **Tendências** centrais: média e mediana.
3. **Padrões** e grupos naturais.
4. **Outliers** e valores estranhos.
5. **Relações** entre pares de variáveis.
6. **Segmentações**: o padrão muda por grupo?
7. **Hipóteses** registradas para testar.

X NO EXCEL, SÓ COM CLIQUES

Os gráficos da exploração sem fórmulas

1. **Histograma.** Selecione a coluna `renda_mensal` e use **Inserir › Gráficos › Inserir Gráfico Estatístico › Histograma**. Para mudar o número de barras, clique no eixo horizontal, **Formatar Eixo › Número de compartimentos**.
2. **Boxplot.** Selecione `gasto_mensal` e use **Inserir Gráfico Estatístico › Caixa e Caule**. Os pontos soltos são os extremos.
3. **Dispersão.** Selecione `renda_mensal` e `gasto_mensal` juntas (segure `Ctrl`) e use **Inserir › Dispersão**. Para a linha de tendência, clique num ponto com o botão direito e escolha **Adicionar Linha de Tendência**.
4. **Comparar grupos. Inserir › Tabela Dinâmica**, com `plano` em Linhas e `gasto_mensal` em Valores. Na seta de "Soma de gasto_mensal", **Configurações do Campo de Valor › Média**. Confira: Básico R$ 185,94, Plus R$ 386,21, Premium R$ 746,27.
5. **Filtrar com um clique.** Com a Tabela Dinâmica selecionada, **Inserir › Segmentação de Dados** e escolha `canal`. Cada clique filtra a tabela.

6 **Contingência.** Numa nova Tabela Dinâmica, `canal` em Linhas, `plano` em Colunas e `id_cliente` em Valores (contagem). Para percentuais: **Mostrar Valores Como › % do Total da Linha**.

P NO PROJETO

No checkpoint do Encontro 5, explorem a base preparada do grupo com as seis perguntas deste capítulo. Registrem três descobertas e duas novas hipóteses, e incluam no arquivo pelo menos três gráficos: um histograma, um boxplot por grupo e uma dispersão.

Para revisar

- EDA é olhar antes de concluir: observar, descrever, comparar, investigar, formular hipóteses.
- Histograma mostra o formato. Média acima da mediana indica cauda à direita.
- Boxplot mostra mediana, quartis e extremos; lado a lado, compara grupos.
- Categorias se resumem em contagens e percentuais; deixe claro o total usado.
- Dispersão mostra direção, forma e força da relação entre duas numéricas.
- Contingência compara grupos de forma justa com o percentual por linha.
- No tempo, separe tendência de sazonalidade comparando com o mesmo período do ano anterior.

Exercícios

1. Num histograma de tempo de espera, a média é 14 minutos e a mediana é 9. O que isso diz sobre o formato da distribuição?
2. Que gráfico você usaria para cada pergunta? (a) A nota de satisfação muda por cidade? (b) Como as vendas evoluíram mês a mês? (c) Idade e gasto andam juntos? (d) Quantos clientes há em cada plano?
3. Numa tabela de contingência, o canal App tem 11 clientes Premium e a Loja tem 6. Dá para dizer que o App atrai mais clientes Premium? O que você faria?
4. Dois boxplots de gasto, um para clientes de Recife e outro para clientes de Olinda, têm medianas diferentes, mas as caixas se sobrepõem quase inteiras. O que você conclui?
5. O faturamento de dezembro foi 30% maior que o de novembro. Isso mostra que a loja está crescendo?
6. Escreva duas hipóteses que poderiam sair de um gráfico de dispersão entre idade e renda que mostra os pontos subindo até os 50 anos e depois descendo.

ENCONTRO 6

6 ESTATÍSTICA DESCRITIVA

AO FINAL DESTE CAPÍTULO VOCÊ VAI SABER

- escolher entre média, mediana e moda conforme o tipo e o formato dos dados;
- medir e interpretar a variação com amplitude, desvio padrão, quartis e IQR;
- interpretar a correlação, reconhecer seus limites e evitar confundir correlação com causa;
- escrever um insight completo, que termina numa ação.

A estatística descritiva resume os dados respondendo a três perguntas: **onde** a maioria dos valores se concentra, **quanto** eles se espalham e se duas variáveis **andam juntas**. Sem uma boa descrição, nenhuma análise mais avançada é confiável.

6.1 Tendência central: média, mediana e moda

MEDIDA	O QUE É	PONTO FORTE	PONTO FRACO
Média	A soma dos valores dividida pela quantidade	Usa todos os valores; é a mais conhecida	Sensível a valores extremos
Mediana	O valor do meio, com os dados em ordem: metade abaixo, metade acima	Resiste a extremos; mostra o valor típico	Ignora quão longe estão os valores das pontas
Moda	O valor que mais se repete	A única que funciona para categorias	Pode não existir ou haver várias

A figura mostra por que a mediana é a medida preferida para renda, preços de imóveis e tempos de espera: um único valor extremo arrasta a média para longe de qualquer pessoa real. A média funciona bem quando a distribuição é simétrica, a variação é baixa e não há extremos fortes.

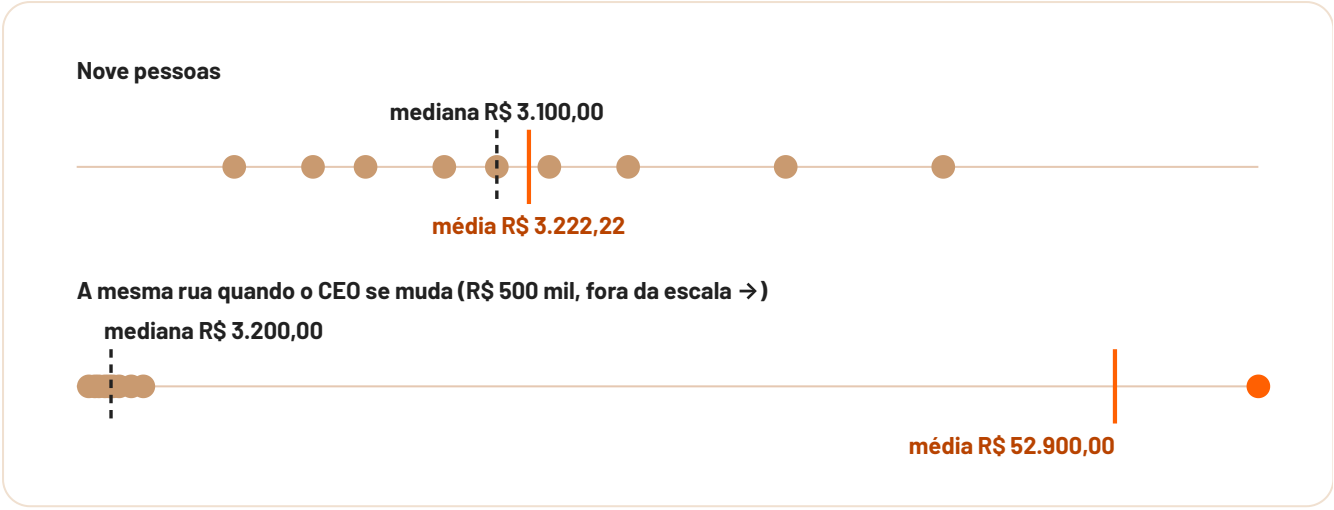


Figura 6.1 · Nove moradores de uma rua e suas rendas. Quando um CEO com renda de R$ 500 mil se muda para a rua, a média dispara; a mediana quase não se mexe.

O que a comparação entre média e mediana revela

- **Média ≈ mediana:** distribuição simétrica; a média representa bem.
- **Média > mediana:** assimetria positiva (cauda à direita); valores altos puxam a média para cima. É o caso da renda dos clientes: média R$ 5.060,67, mediana R$ 3.889,40.
- **Média < mediana:** assimetria negativa (cauda à esquerda); valores baixos puxam a média para baixo.

SITUAÇÃO	MELHOR MEDIDA
Renda de um bairro onde vivem alguns milionários	Mediana
Tamanho de calçado mais vendido, para planejar o estoque	Moda
Notas de uma turma em que todos tiraram entre 6 e 8	Média (a mediana também serve)
Tempo de entrega com alguns pedidos muito atrasados	Mediana
Canal de atendimento preferido	Moda

Σ POR TRÁS DA CONTA

As três contas, em palavras

Média: some todos os valores e divida pela quantidade. Rendas de 2, 3 e 10 mil dão (2 + 3 + 10) ÷ 3 = 5 mil.

Mediana: coloque em ordem e pegue o do meio. Para 2, 3 e 10 mil, é 3 mil. Com uma quantidade par, é o ponto entre os dois do meio.

Moda: conte quantas vezes cada valor aparece e fique com o mais frequente.

6.2 Dispersão: o quanto os dados se espalham

O centro diz onde os dados estão; a dispersão diz o quanto eles variam. Duas distribuições podem ter a mesma média e serem completamente diferentes.

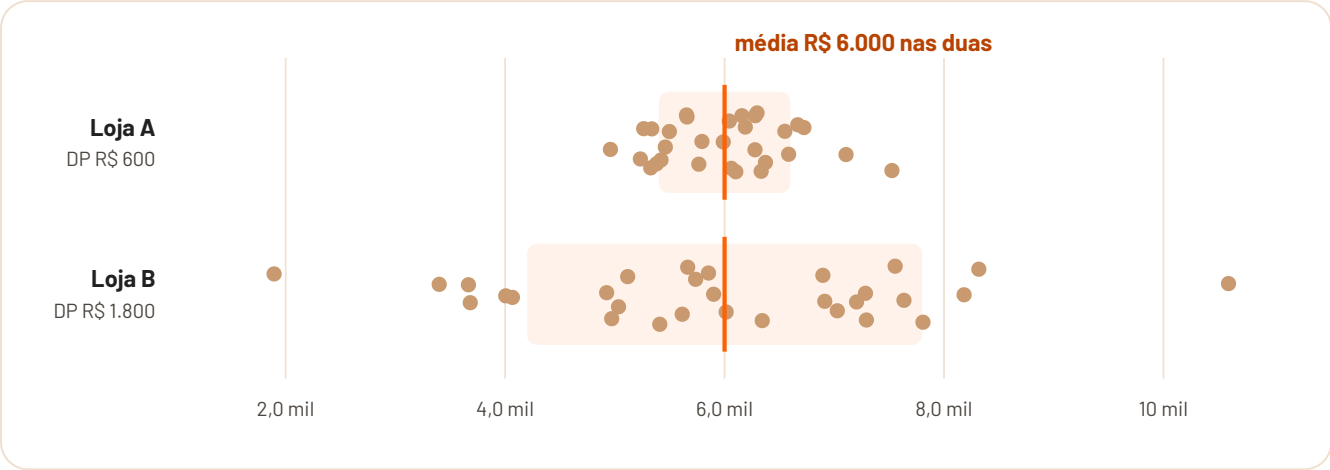


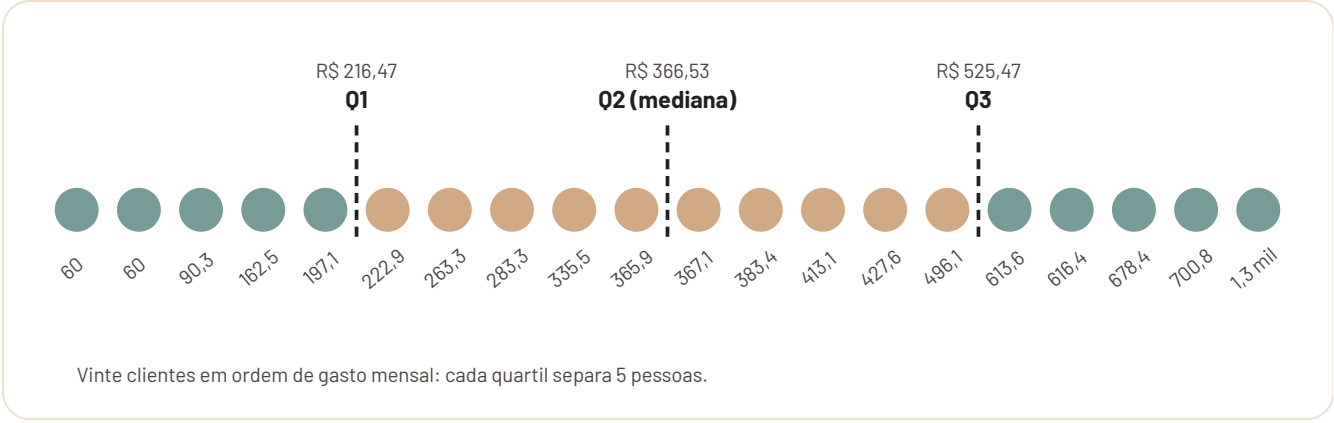
Figura 6.2 · Vendas diárias de duas lojas em 30 dias. As duas vendem, em média, R$ 6.000 por dia. A loja B varia três vezes mais: a faixa sombreada (média ± 1 desvio padrão) é muito mais larga.

Administrar as duas lojas é diferente: a loja A é previsível; a loja B tem dias muito fracos e muito fortes, o que exige mais estoque de segurança e mais cuidado com o caixa.

MEDIDA	O QUE É	COMO LER
Amplitude	Maior valor menos o menor	Simples, mas um único extremo a estraga
Variância	A média dos quadrados das distâncias até a média	Fica em unidade ao quadrado (reais^2), difícil de interpretar
Desvio padrão	A raiz quadrada da variância	A distância típica de um valor até a média, na mesma unidade dos dados
Quartis	Os valores que dividem os dados ordenados em quatro partes iguais	Q1, Q2 (a mediana) e Q3
IQR	Q3 − Q1	A largura dos 50% do meio; resiste a extremos

Um exemplo de leitura do desvio padrão: se a idade média dos clientes é 35 anos com desvio de 8 anos, a maior parte deles está, grosso modo, entre 27 e 43 anos. Na base de clientes, a idade média é 39,2 anos com desvio de 11,7: um público variado.

Quartis em fila



Vinte clientes em ordem de gasto mensal: cada quartil separa 5 pessoas.

Figura 6.3 · Vinte clientes em fila, do menor para o maior gasto mensal. Os quartis dividem a fila em quatro grupos de cinco pessoas.

Se um cliente com gasto enorme entrar no fim da fila, a média muda bastante, mas os quartis quase não se mexem: ele só ocupa a última posição. É por isso que IQR e mediana são chamados de medidas **robustas**.

Quando a variação é alta

Sinais de que os dados são heterogêneos e talvez precisem ser separados em grupos:

- o desvio padrão passa de 30% da média (essa razão se chama **coeficiente de variação**);
- a amplitude é desproporcional à mediana;
- o IQR é largo;
- há muitos valores além das cercas.

Na renda dos clientes, o desvio padrão é R$ 4.567,50, cerca de 90% da média, e 15 clientes passam da cerca superior de R$ 10.702,61. É uma variável muito heterogênea: vale segmentar em faixas de renda antes de comparar.

Σ POR TRÁS DA CONTA

Desvio padrão, em palavras

Para cada valor, a ferramenta mede a distância até a média e eleva ao quadrado (assim distâncias para cima e para baixo não se anulam). Depois tira a média desses quadrados, que é a variância, e a raiz quadrada, que devolve o resultado à unidade original. O desvio padrão é, portanto, uma espécie de "distância típica até a média".

Existem duas versões: a da **amostra** (divide por um a menos que a quantidade) e a da **população** (divide pela quantidade). Quando os dados são uma parte de um grupo maior, como quase sempre, usa-se a da amostra. Com muitos dados, a diferença é pequena.

6.3 Correlação: quando uma sobe, a outra sobe?

A **correlação** (de Pearson, representada por *r*) mede a força e a direção da relação em linha reta entre duas variáveis numéricas. Ela vai de −1 a +1:

- **positiva:** quando uma aumenta, a outra tende a aumentar (anos de estudo e renda);
- **negativa:** quando uma aumenta, a outra tende a diminuir (tempo de entrega e nota do cliente);
- **perto de zero:** não há relação em linha reta.

VALOR DE R, SEM O SINAL	FORÇA	LEITURA
0,0 a 0,3	Fraca	As variáveis se movem de forma quase independente
0,3 a 0,6	Moderada	Há relação perceptível, mas com muita variação; outros fatores pesam
0,6 a 1,0	Forte	As variáveis se movem juntas de forma consistente

Esses intervalos são uma convenção. O contexto importa: uma correlação de 0,4 pode ser relevante em pesquisas sobre comportamento humano e fraca em física.



Figura 6.4 · Seis nuvens de pontos e suas correlações. A última mostra uma relação clara em curva com r perto de zero: a correlação de Pearson só enxerga relações em linha reta.

Na base de clientes, a correlação entre renda e gasto é 0,85 (forte e positiva), e entre renda e idade é -0,05 (praticamente nenhuma relação em linha reta).

Três armadilhas da correlação

1. Um único ponto extremo pode inventar uma relação.

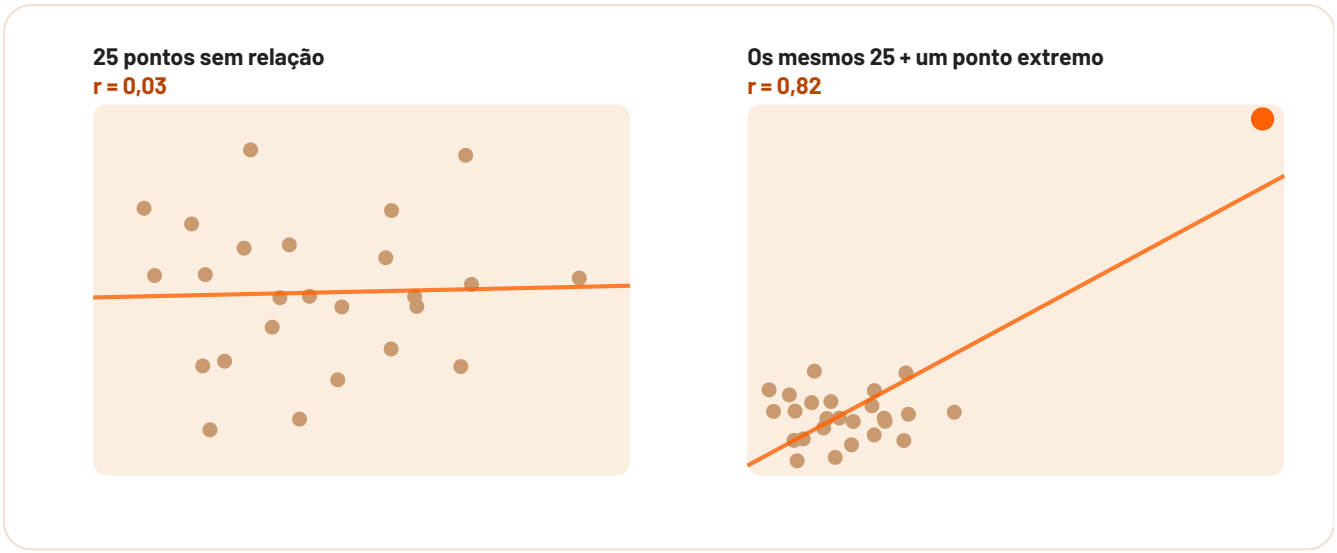


Figura 6.5 · À esquerda, 25 pontos sem relação. À direita, os mesmos 25 e mais um ponto extremo: a correlação salta, embora nada tenha mudado no resto dos dados.

2. A relação pode existir só dentro de alguns grupos. A correlação entre idade e gasto pode ser fraca no geral e forte entre os clientes de uma cidade. Quando a correlação geral for fraca ou estranha, calcule-a separadamente por grupo.

3. Correlação não é causalidade. Variáveis que se movem juntas não necessariamente se explicam. O exemplo clássico: em dias quentes, vendem-se mais sorvetes e há mais afogamentos. Sorvete não causa afogamento; a temperatura (uma terceira variável, escondida) aumenta as duas coisas.

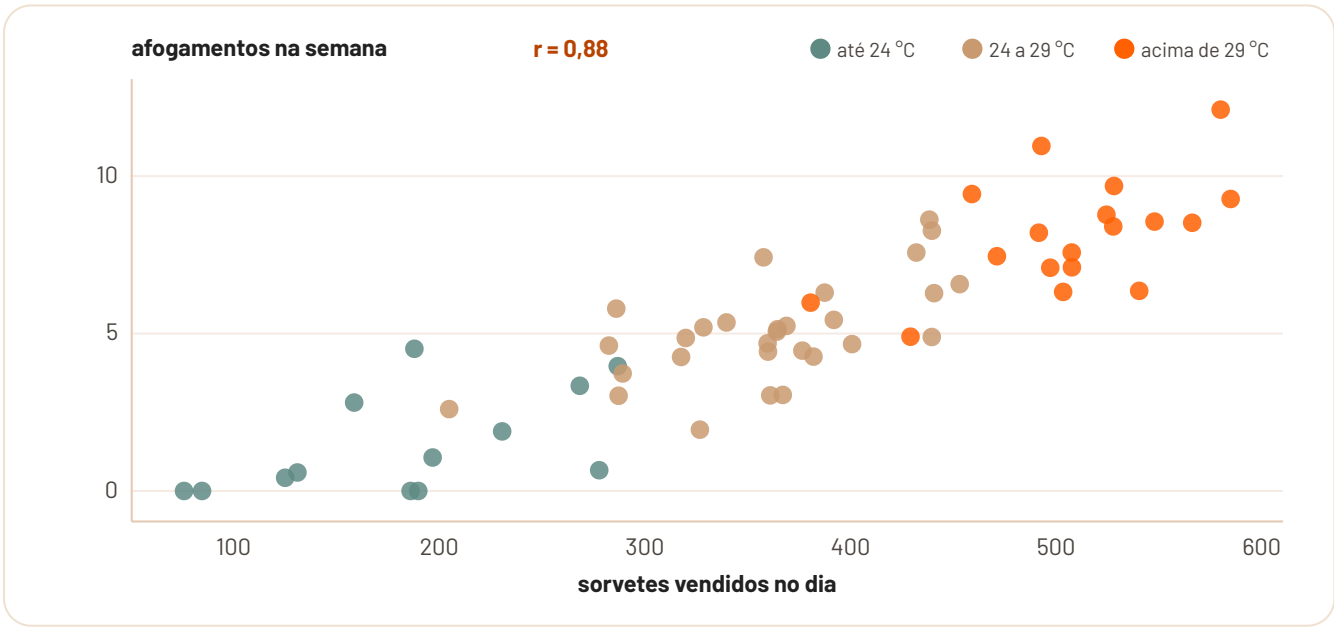


Figura 6.6 · Sorvetes vendidos e afogamentos (dados de exemplo). A correlação é forte, mas as cores mostram a causa comum: os dias mais quentes estão no alto à direita.

Para afirmar causa, é preciso mais do que correlação: um experimento controlado, acompanhamento ao longo do tempo e uma explicação plausível de como uma coisa provoca a outra.

E EXEMPLO

Checklist antes de interpretar uma correlação

1. **A relação é forte?** Olhe o valor de r sem o sinal.
2. **Qual o sentido?** Positivo ou negativo?
3. **Faz sentido no contexto?** Existe uma explicação de negócio, ou pode ser coincidência?
4. **Há extremos influenciando?** Recalcule sem eles e veja se a correlação se mantém.

6.4 Do número ao insight

Um número sozinho não é um insight. O insight nasce quando combinamos as três dimensões da estatística descritiva e dizemos o que isso significa:

1. **Descreva** o comportamento da variável (centro);
2. **mostre** a variação (dispersão);
3. **relacione** com outra variável (correlação ou comparação de grupos);
4. **proponha** o que isso significa e o que fazer.

SÓ UM NÚMERO

"A correlação entre renda e gasto é 0,85."

Correto, mas não diz o que fazer.

INSIGHT COMPLETO

"O gasto acompanha a renda de perto (r = 0,85), e a renda é muito desigual entre os clientes. Faixas de renda são um bom critério para segmentar ofertas."

Um mini roteiro ajuda a conferir se o insight está completo:

PERGUNTA	O QUE RESPONDER
O quê?	O achado principal, em uma frase clara
Por quê?	O contexto ou a explicação provável
Quanto?	O número: percentual, diferença, coeficiente
Com quem?	O grupo, segmento ou variável envolvidos
E daí?	O impacto no negócio e a ação recomendada

X NO EXCEL, SÓ COM CLIQUES

Todas as medidas sem escrever fórmula

1. **Barra de status.** Clique na letra da coluna `renda_mensal`. No canto inferior direito aparecem Média e Contagem. Clique com o botão direito na barra e ative **Mínimo** e **Máximo**. Confira a média: R$ 5.060,67.
2. **Várias medidas por grupo. Inserir › Tabela Dinâmica**, com `plano` em Linhas e `gasto_mensal` três vezes em Valores. Em cada uma, **Configurações do Campo de Valor**: Média, DesvPad e Máx.
3. **Ligue as Ferramentas de Análise** (uma vez só): **Arquivo › Opções › Suplementos**, em Gerenciar escolha **Suplementos do Excel › Ir** e marque Ferramentas de Análise. Aparece o botão **Análise de Dados** na guia Dados. Só existe no Excel instalado (Windows ou Mac), não no Excel na web.
4. **Prepare colunas sem vazios.** Filtre `renda_mensal` e `gasto_mensal` tirando (Vazias), copie as duas colunas visíveis e cole numa aba nova. Ficam 173 clientes.
5. **Estatística descritiva. Dados › Análise de Dados › Estatística descritiva**. Intervalo: as duas colunas com cabeçalho; marque **Rótulos na primeira linha** e **Resumo estatístico**. Confira para a renda: média R$ 4.899,51, mediana R$ 3.889,40, desvio padrão R$ 3.737,46.
6. **Correlação. Dados › Análise de Dados › Correlação**, mesmo intervalo, com rótulos. A tabela mostra 0,85 entre renda e gasto.

Σ POR TRÁS DA CONTA

Correlação, em palavras

Para cada cliente, a ferramenta verifica se ele está acima ou abaixo da média em renda e em gasto. Quando a maioria está acima nas duas ao mesmo tempo (ou abaixo nas duas), a correlação é positiva. Quando um está acima e o outro abaixo, é negativa. O resultado é ajustado para ficar sempre entre −1 e +1, sem depender da unidade de cada variável.

P NO PROJETO

No checkpoint do Encontro 6, o grupo escolhe duas hipóteses e testa cada uma com a análise adequada: correlação, quando as duas variáveis são numéricas; comparação de médias ou análise por grupos, quando uma é categórica. Registre as variáveis usadas, a análise, o resultado e o veredito.

Para revisar

- Média usa todos os valores e é sensível a extremos; mediana é o valor do meio e resiste a eles; moda é o mais frequente e serve para categorias.
- Média acima da mediana indica cauda à direita.
- Desvio padrão é a distância típica até a média, na unidade dos dados. IQR é a largura dos 50% do meio.
- Desvio padrão acima de 30% da média sinaliza dados heterogêneos: considere segmentar.
- Correlação vai de −1 a +1 e só mede relação em linha reta. Fraca até 0,3, moderada até 0,6, forte acima.
- Extremos inventam correlações; grupos escondem correlações; correlação não prova causa.
- Insight completo: o quê, por quê, quanto, com quem e e daí.

Exercícios

1. Os salários de uma pequena empresa são R$ 2.000, R$ 2.200, R$ 2.500, R$ 2.800 e R$ 30.000. Calcule a média e a mediana. Qual descreve melhor o salário típico?
2. Duas turmas têm nota média 7. Na turma A, o desvio padrão é 0,5; na turma B, é 2,5. Descreva a diferença entre elas.
3. Classifique a força e o sentido: (a) $r = 0{,}82$; (b) $r = -0{,}45$; (c) $r = 0{,}12$; (d) $r = -0{,}67$.
4. Uma análise encontrou correlação de 0,7 entre o número de bombeiros enviados a um incêndio e o prejuízo causado. Dá para concluir que mandar menos bombeiros reduziria o prejuízo?
5. A correlação entre idade e gasto, na base inteira, é 0,05. Que análise adicional você faria antes de concluir que não há relação?
6. Reescreva como insight completo: “O plano Premium tem gasto médio de R$ 746”.

ENCONTRO 7

7 PROJETO INTEGRADOR

AO FINAL DESTE CAPÍTULO VOCÊ VAI SABER

- organizar a análise completa nas seis abas do arquivo final;
- revisar criticamente a pergunta, as hipóteses e as variáveis do projeto;
- dar a cada hipótese um veredito com argumento, incluindo o inconclusivo;
- escrever de 10 a 14 insights em quatro categorias e uma conclusão para um gestor.

O Projeto Integrador junta tudo: pergunta, coleta, limpeza, preparação, exploração, estatística e comunicação. O objetivo da atividade final é validar ou refutar as hipóteses levantadas no Encontro 2, verificar se as perguntas iniciais são respondíveis com os dados, gerar insights ligados ao problema de negócio e refletir sobre a qualidade dos dados e os limites da análise.

> **O foco não é acertar as hipóteses. É argumentar bem com base nos dados.**

Os exemplos deste capítulo usam a base de delivery que acompanha o Laboratório do projeto: 70 pedidos de um aplicativo, com a pergunta “quais fatores estão associados a entregas mais demoradas e a notas mais baixas?”.

7.1 O arquivo final, aba por aba

A entrega é um único arquivo por grupo, com o nome do grupo no arquivo e na primeira aba. As abas seguem a ordem do processo analítico.

ABA	O QUE ENTRA
0_Documentação	Tema, pergunta principal, perguntas secundárias, hipóteses, dicionário de variáveis e o bloco de reflexão crítica
1_Base_Bruta	A base exatamente como foi recebida, sem nenhuma alteração
2_Base_Limpa	A base limpa e, ao lado, o log: o que foi feito, por que e o risco de não fazer

ABA	O QUE ENTRA
3_Preparação	A base com pelo menos 3 colunas derivadas e a tabela que explica cada uma
4_Outliers_e_Correlação	Outliers com contexto de negócio e o teste de pelo menos duas hipóteses
5_Insights_e_Validação	De 10 a 14 insights em quatro categorias e a conclusão para o gestor

O Laboratório do projeto faz as contas de cada etapa e copia os resultados prontos para colar na aba certa. No Excel, o grupo organiza, formata e escreve as justificativas.

7.2 Revisão crítica do projeto

Antes de olhar os resultados, revise o próprio projeto. A aba 0_Documentação precisa responder a três perguntas, por escrito.

1. **As variáveis disponíveis são suficientes para responder à pergunta principal?** Sim, parcialmente ou não, com justificativa. Exemplo: "Parcialmente. Temos distância, chuva e experiência do entregador, mas não temos o tempo de preparo no restaurante, que também pode atrasar a entrega."
2. **Alguma pergunta do Encontro 2 não pode ser respondida com esta base?** Qual, por quê e que variável estaria faltando. Exemplo: "Clientes que usam cupom voltam a pedir? Não dá para saber: cada linha é um pedido e não há identificação do cliente. Faltaria `id_cliente`."
3. **Alguma hipótese inicial está mal definida, é genérica demais ou não é testável com dados?** Explique com exemplos.

HIPÓTESE	PROBLEMA	VERSÃO TESTÁVEL
"O app tem problemas."	Genérica demais: não diz qual problema	"Pedidos pelo app demoram mais do que por telefone."
"A chuva atrapalha as entregas."	Mal definida: atrapalha como?	"Com chuva, o tempo médio de entrega é maior."
"Clientes avaliam melhor quando o entregador é simpático."	Não testável: a base não mede simpatia	Precisaria de uma pergunta de avaliação do entregador
"O preço do concorrente faz o cliente desistir."	Não testável: não há preços de concorrentes nem pedidos desistidos	Precisaria de dados de carrinhos abandonados

7.3 Limpeza, preparação e outliers com justificativa

As técnicas são as dos capítulos 3 e 4. O que muda no projeto final é o reforço analítico: para cada decisão de limpeza, o grupo responde o que foi feito, por que foi feito dessa forma e qual seria o risco de não fazer. A limpeza precisa cobrir vazios (identificação e decisão), duplicatas, inconsistências (de valores, categorias e

datas) e padronização.

Para cada coluna derivada, o grupo informa a regra (ou fórmula), a coluna original, a coluna nova, a pergunta ou hipótese que ela ajuda a responder e se, sem ela, a análise ficaria impossível, incompleta ou menos interpretável.

Para os outliers, depois da detecção pelo IQR, o grupo diz se eles representam erro de dado, comportamento extremo real ou ambos, e se decidiu manter, remover ou manter parcialmente, com uma justificativa de negócio. "Passou da cerca" não é justificativa; "era um pedido corporativo real, que o negócio quer atender" é.

7.4 Testar hipóteses e dar o veredito

Para pelo menos duas hipóteses, registre:

1. **as variáveis usadas** para testá-la;
2. **o tipo de análise:** correlação (duas variáveis numéricas), comparação de médias (uma variável numérica entre dois grupos) ou análise por grupos (vários grupos ou faixas);
3. **o resultado encontrado**, com o número;
4. **o veredito** e a justificativa.

VEREDITO	QUANDO USAR
Confirma	A evidência vai na direção esperada e é clara: relação moderada ou forte, ou diferença relevante entre grupos
Parcial	Vale só para parte dos casos ou com ressalvas importantes
Refuta	A evidência é clara e não mostra o efeito esperado, ou mostra o contrário
Inconclusivo	Os dados não permitem decidir: relação fraca, poucos casos, variável faltando ou outra explicação possível. Diga por quê.

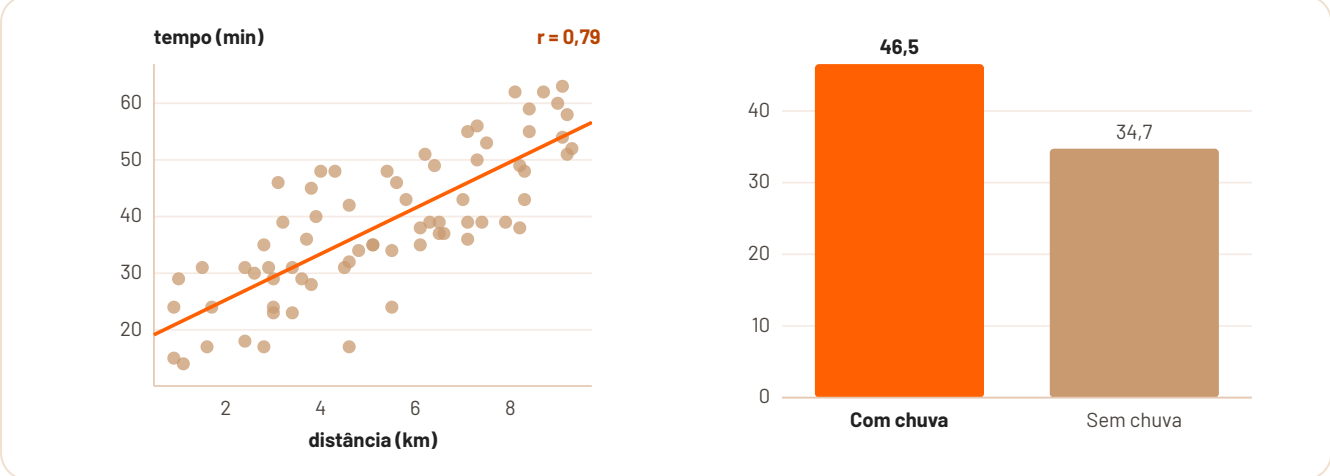


Figura 7.1 · Duas hipóteses da base de delivery. À esquerda, distância e tempo de entrega sobem juntos. À direita, o tempo médio com e sem chuva.

E EXEMPLO

As cinco hipóteses da base de delivery

HIPÓTESE	ANÁLISE	RESULTADO	VEREDITO
Quanto maior a distância, maior o tempo de entrega	Correlação	r = 0,79	Confirma
Pedidos em dias de chuva demoram mais	Comparação de médias	46,5 × 34,7 min	Confirma
Entregas mais demoradas recebem notas menores	Correlação	r = –0,67	Confirma (ou Parcial, com justificativa)
Entregadores mais experientes entregam mais rápido	Correlação	r = –0,14	Inconclusivo
Pedidos por telefone recebem notas menores que pelo app	Comparação de médias	4,14 × 4,11	Refuta

Com chuva, a entrega leva em média 34% a mais (24 pedidos com chuva). A nota pelo app e por telefone difere em centésimos numa escala de 1 a 5: o efeito esperado não aparece.

! CUIDADO

Inconclusivo não é fracasso

"A relação entre experiência e tempo é fraca (r = –0,14). Separando por faixas, quem tem 2 anos ou mais entrega um pouco mais rápido, mas são poucos entregadores por faixa. Precisaríamos de mais meses de dados." Explicar por que não dá para concluir também é um resultado: mostra que o grupo conhece o limite da base.

7.5 Insights em quatro categorias

A aba 5_Insights_e_Validação reúne de 10 a 14 insights, distribuídos obrigatoriamente em quatro categorias. Cada um deve ter número, comparação e consequência.

CATEGORIA	O QUE COBRE	EXEMPLO COM A BASE DE DELIVERY
Qualidade dos dados	Problemas encontrados e o impacto na análise	Bairro aparecia com 13 grafias para 7 bairros; sem padronizar, o tempo médio por bairro seria calculado em grupos falsos.

CATEGORIA	O QUE COBRE	EXEMPLO COM A BASE DE DELIVERY
Insights analíticos	Padrões, comportamentos, segmentações	Com chuva, o tempo médio sobe de 34,7 para 46,5 minutos (34%); dias de chuva pedem mais entregadores ou prazo maior.
Validação das perguntas	O problema foi bem formulado? O dataset respondeu o que prometia?	A pergunta foi respondida em parte: distância e chuva explicam boa parte do tempo, mas falta o tempo de preparo no restaurante.
Recomendações	De negócio, de coleta e de melhoria do dataset	Registrar o tempo de preparo e a identificação do cliente, para separar atraso da cozinha de atraso da rua e medir recompra.

7.6 A conclusão para o gestor

A atividade termina com uma resposta de até cinco linhas para a pergunta: **se esse projeto fosse apresentado a um gestor, qual decisão ele poderia tomar com base nesses dados?**

FRACA

"Os dados mostram várias coisas interessantes sobre as entregas e é importante continuar analisando."

Não diz qual decisão, não usa número, não reconhece limites.

FORTE

"O gestor pode ampliar em 10 minutos o prazo prometido em dias de chuva e acima de 6 km, onde o tempo é maior e as notas caem. Não vale investir no app para melhorar notas: não houve diferença. Falta medir o tempo de preparo."

Uma boa conclusão tem três partes: uma **decisão** clara, a **evidência** que a sustenta e o **limite** do que os dados permitem afirmar.

7.7 Como o projeto é avaliado

O projeto vale 40% da nota da disciplina. Os critérios refletem as partes da atividade final:

CRITÉRIO	PESO	O QUE SE ESPERA
Documentação e reflexão crítica	15%	Reflexão que responde às três perguntas com exemplos do próprio dataset
Limpeza justificada	20%	Todos os tipos de problema tratados; log com o quê, por quê e risco
Preparação	10%	3 ou mais colunas derivadas ligadas a hipóteses, com regra e impacto
Outliers com contexto	10%	Classificação e decisão com argumento de negócio

CRITÉRIO	PESO	O QUE SE ESPERA
Validação de hipóteses	20%	2 ou mais hipóteses com análise adequada, veredito e inconclusivos explicados
Insights e recomendações	15%	10 a 14, nas 4 categorias, com número, comparação e consequência
Conclusão para o gestor	5%	Até 5 linhas, com decisão, evidência e limite
Organização do arquivo	5%	Seis abas certas, blocos legíveis, grupo identificado

X NO EXCEL, SÓ COM CLIQUES

Montar o arquivo final

1. **Confiram as seis abas.** Os nomes precisam ser exatamente os da tabela. Para renomear, clique duas vezes no nome da aba.
2. **Colem cada bloco no lugar certo.** No Laboratório, aba "Levar ao Excel", clique em Copiar; no Excel, clique na célula indicada e cole. Os blocos "ao lado da base" começam uma coluna depois da última coluna da base.
3. **Transformem cada bloco em tabela** com **Página Inicial › Formatar como Tabela**.
4. **Deixem os textos legíveis:** selecione as colunas de texto longo e use **Página Inicial › Quebrar Texto Automaticamente**.
5. **Fixem o cabeçalho** das bases com **Exibir › Congelar Painéis › Congelar Linha Superior**.
6. **Coloquem os gráficos** que sustentam os vereditos na aba 4: dispersão para correlações, Caixa e Caule para comparar grupos.
7. **Identifiquem o grupo** na célula A1 da aba 0 e no nome do arquivo (por exemplo, Grupo3_ProjetoFinal.xlsx).

7.8 Checklist de entrega

- Tema, pergunta principal e secundárias, hipóteses e dicionário na aba 0.
- Reflexão crítica com as três perguntas respondidas e exemplos.
- Base original intacta na aba 1.
- Vazios, duplicatas, inconsistências e padronização tratados, com log completo.
- Pelo menos 3 colunas derivadas, com regra, origem, pergunta e impacto.
- Outliers classificados e decididos com argumento de negócio.
- Pelo menos 2 hipóteses testadas, com inconclusivos explicados.
- De 10 a 14 insights nas 4 categorias.

- Conclusão em até 5 linhas.
- Um único arquivo, com o nome do grupo.

Para revisar

- Seis abas, na ordem do processo: documentação, bruta, limpa, preparação, outliers e correlação, insights e validação.
- A reflexão crítica avalia se as variáveis bastam, que pergunta ficou sem resposta e que hipótese estava mal formulada.
- Cada hipótese leva variáveis, análise, resultado e veredito. Inconclusivo exige explicação.
- Insights cobrem qualidade dos dados, padrões, validação das perguntas e recomendações.
- A conclusão para o gestor tem decisão, evidência e limite, em até cinco linhas.

Exercícios

1. Uma hipótese de projeto dizia “clientes jovens compram mais”. Avalie e reescreva de forma testável.
2. Para cada hipótese, indique o tipo de análise: (a) o tempo de entrega aumenta com a distância; (b) pedidos com cupom têm valor médio maior; (c) o tempo de entrega muda entre os sete bairros atendidos.
3. Um grupo encontrou r = 0,18 entre o desconto e a nota do cliente e marcou “Refuta”. Você concorda?
4. Escreva um insight da categoria “Recomendações de coleta” para uma base de vendas em que 40% dos pedidos não têm a cidade preenchida.
5. Reescreva esta conclusão para que tenha decisão, evidência e limite: “As entregas atrasam por vários motivos e o cliente fica insatisfeito”.

APÊNDICE A

A GLOSSÁRIO

Os termos da disciplina em ordem alfabética, com o capítulo onde aparecem com mais detalhe.

Amostra	Parte de um grupo maior (a população) usada para estudá-lo. Se não for representativa, gera viés. (Cap. 1)
Amplitude	Maior valor menos o menor. Simples, mas sensível a extremos. (Cap. 6)
Assimetria	Quando a distribuição tem uma cauda mais longa de um lado. À direita, a média fica acima da mediana. (Cap. 5)
Boxplot	Gráfico de caixa: mostra mediana, quartis, bigodes e extremos de uma variável. (Cap. 5)
Categorização	Transformar um número em faixas (baixo, médio, alto). (Cap. 4)
Cerca	Limite a partir do qual um valor é marcado como outlier: Q1 − 1,5 × IQR e Q3 + 1,5 × IQR. (Cap. 4)
Coeficiente de variação	Desvio padrão dividido pela média. Acima de 30%, indica dados heterogêneos. (Cap. 6)
Coluna derivada	Coluna nova criada a partir de outras (faixa de preço, mês, prazo em dias). (Cap. 4)
Correlação	Medida de −1 a +1 da força e da direção da relação em linha reta entre duas variáveis numéricas. (Cap. 6)
Dado	Registro bruto de uma característica observável. (Cap. 1)
Desvio padrão	Distância típica dos valores até a média, na mesma unidade dos dados. (Cap. 6)
Dicionário de dados	Documento que descreve cada variável: significado, tipo, unidade, valores possíveis e fonte. (Cap. 1)
Dispersão (gráfico)	Gráfico com uma variável em cada eixo; cada ponto é um registro. (Cap. 5)
Distribuição	O jeito como os valores de uma variável se espalham. (Cap. 5)
Duplicata	Registro que aparece mais de uma vez. Exata quando tudo é igual; parcial quando só a chave se repete. (Cap. 3)
EDA	Análise exploratória de dados: olhar os dados com curiosidade antes de concluir. (Cap. 5)
Escala de medição	Nominal, ordinal, intervalar ou razão; define que operações fazem sentido. (Cap. 1)
Granularidade	Nível de detalhe de cada linha da base (venda, dia, mês). (Cap. 2)

Hipótese	Resposta provisória a uma pergunta, que será testada com dados. (Cap. 2)
Histograma	Gráfico de barras que conta quantos valores caem em cada intervalo. (Cap. 5)
Identificador	Campo que nomeia um registro (código, CEP, CPF); não é quantidade. (Cap. 1)
Imputação	Preencher valores ausentes com uma estimativa (mediana, média, moda). (Cap. 3)
Informação	Dado com contexto e significado. (Cap. 1)
Insight	Achado com significado: o quê, por quê, quanto, com quem e e daí. (Cap. 6)
IQR	Intervalo interquartil: Q3 – Q1, a largura dos 50% do meio. (Cap. 4)
Log de limpeza	Registro de cada decisão de limpeza: o que foi feito, por que e o risco de não fazer. (Cap. 3)
Média	Soma dos valores dividida pela quantidade. (Cap. 6)
Mediana	Valor do meio com os dados em ordem. (Cap. 6)
Moda	Valor mais frequente. (Cap. 6)
Normalização	Transformar valores para a escala de 0 a 1 usando o mínimo e o máximo. (Cap. 4)
Outlier	Valor muito distante dos demais; pode ser erro ou caso real. (Cap. 4)
Padronização (escore z)	Quantos desvios padrão um valor está acima ou abaixo da média. (Cap. 4)
Pipeline analítico	Sequência de etapas da pergunta à comunicação, percorrida em ciclo. (Cap. 2)
Quartis	Valores que dividem os dados ordenados em quatro partes iguais: Q1, Q2 (mediana) e Q3. (Cap. 6)
Sazonalidade	Padrão que se repete em períodos fixos, como os picos de fim de ano. (Cap. 5)
Tabela de contingência	Cruzamento de duas variáveis categóricas, com contagens ou percentuais. (Cap. 5)
Tendência	Movimento de longo prazo de uma série no tempo. (Cap. 5)
Variância	Média dos quadrados das distâncias até a média; o desvio padrão é sua raiz. (Cap. 6)
Variável	Característica que muda de um registro para outro; cada coluna da tabela. (Cap. 1)
Veredito	Conclusão sobre uma hipótese: confirma, parcial, refuta ou inconclusivo. (Cap. 7)
Viés	Distorção sistemática que faz os dados contarem uma história diferente da realidade. (Cap. 1)

APÊNDICE B

B ONDE CLICAR NO EXCEL

Todos os caminhos do Excel usados na disciplina, sem nenhuma fórmula.

PARA	CAMINHO	CAP.
Abrir um CSV com ponto e vírgula	Dados › Obter Dados › De Arquivo › De Texto/CSV	1
Transformar a base em tabela com filtros	Página Inicial › Formatar como Tabela	1
Ver média, contagem, mínimo e máximo	Selecionar a coluna e olhar a barra de status (botão direito para escolher as medidas)	1, 6
Contar vazios de uma coluna	Seta do filtro › marcar só (Vazias) › ler "X de Y registros encontrados"	3
Realçar células vazias	Página Inicial › Formatação Condicional › Nova Regra › Formatar apenas células que contenham › Vazias	3
Remover cópias exatas	Dados › Remover Duplicatas, com todas as colunas marcadas	3
Remover repetidos por chave	Ordenar pela data mais recente › Dados › Remover Duplicatas, marcando só a chave	3
Trocar grafias erradas	Página Inicial › Localizar e Selecionar › Substituir, com Coincidir conteúdo da célula inteira	3
Preencher várias células vazias de uma vez	Filtrar (Vazias), selecionar, digitar o valor e pressionar Ctrl+Enter	3
Listar todas as grafias de uma coluna	Inserir › Tabela Dinâmica, com a coluna em Linhas	3
Ver os maiores valores	Seta do filtro › Classificar do Maior para o Menor	4
Realçar valores acima da cerca	Página Inicial › Formatação Condicional › Realçar Regras das Células › É Maior do que	4
Histograma	Inserir › Gráficos › Inserir Gráfico Estatístico › Histograma	5
Mudar o número de barras	Clicar no eixo › Formatar Eixo › Número de compartimentos	5
Boxplot	Inserir Gráfico Estatístico › Caixa e Caule	5

PARA	CAMINHO	CAP.
Dispersão com linha de tendência	Inserir › Dispersão › botão direito num ponto › Adicionar Linha de Tendência	5
Média por grupo	Tabela Dinâmica › Valores › Configurações do Campo de Valor › Média	5, 6
Filtrar com botões	Com a Tabela Dinâmica selecionada: Inserir › Segmentação de Dados	5
Percentual por linha	Tabela Dinâmica › Mostrar Valores Como › % do Total da Linha	5
Ativar as Ferramentas de Análise	Arquivo › Opções › Suplementos › Suplementos do Excel › Ir › Ferramentas de Análise	6
Resumo estatístico completo	Dados › Análise de Dados › Estatística descritiva	6
Tabela de correlações	Dados › Análise de Dados › Correlação	6
Quebrar texto longo	Página Inicial › Quebrar Texto Automaticamente	7
Fixar o cabeçalho	Exibir › Congelar Painéis › Congelar Linha Superior	7

APÊNDICE C

C RESPOSTAS DOS EXERCÍCIOS

As respostas trazem o raciocínio esperado. Em perguntas abertas, outras respostas também estão corretas se seguirem o mesmo raciocínio.

Capítulo 1 · Fundamentos de Dados

1. (a) Quantitativa contínua, escala intervalar: o zero em °C não é ausência de temperatura. (b) Quantitativa contínua, escala de razão: zero milissegundo é ausência de tempo, e 400 ms é o dobro de 200 ms. (c) Qualitativa ordinal: há hierarquia entre os cargos, mas não uma distância medida. (d) Qualitativa ordinal: fundamental, médio e superior têm ordem.
2. Que a conta existe, mas não tem significado: CEP é um identificador, escrito com algarismos, e não uma quantidade. Para essa coluna, os resumos adequados são contagem e percentual por CEP (ou por região), e a moda.
3. (a) Contagem ou percentual por canal e a moda (o canal mais usado). (b) Mediana, moda ou percentual de notas 4 e 5; a média pode ser usada com ressalva. (c) Mediana, porque resiste aos valores muito altos. (d) Contagem de cadastros por mês ou ano, e a data do primeiro e do último cadastro.
4. Exemplo: dado "52"; informação "o pedido D512 levou 52 minutos para chegar, num dia de chuva, a 8 km do restaurante"; conhecimento "entregas acima de 6 km em dias de chuva demoram em média mais de 45 minutos e recebem notas menores"; decisão "ampliar o prazo prometido nessas condições e avisar o cliente". Qualquer resposta com os quatro degraus, cada um acrescentando contexto ou interpretação ao anterior, está correta.
5. Viés de coleta: só responde quem comprou pelo aplicativo e acabou de ter uma experiência bem-sucedida. Ficam de fora quem desistiu da compra, quem compra por outros canais e quem teve problema. O resultado tende a superestimar a satisfação. Uma amostra sorteada entre todos os clientes corrigiria isso.
6. Parece que quem espera mais dá notas menores e não volta a comprar, e que o telefone concentra as esperas longas. O cuidado é o tamanho: cinco clientes são poucos para concluir. Antes de agir, seria preciso olhar mais clientes (no exemplo com 200, a diferença continua, mas é menor) e verificar se o canal não está misturado com outro fator.

Capítulo 2 · Processo de Análise

1. Exemplo de pergunta principal: "Em quais categorias e canais as vendas online caíram nos últimos 6 meses, e o que mudou nesses grupos?". Secundárias: "Quais categorias tiveram maior queda?"; "A queda é igual em todos os canais de aquisição?"; "O preço médio ou o frete mudaram no período?". Qualquer resposta específica, com período e mensurável, está adequada.
2. (a) Descritiva. (b) Diagnóstica. (c) Comparativa. (d) Temporal. (e) Preditiva.
3. Por exemplo: "pedidos feitos pelo app recebem notas maiores do que pedidos feitos por telefone" ou "pedidos pelo app são entregues mais rápido do que por telefone". A reescrita precisa dizer o que é "melhor" (nota, tempo, cancelamento), qual a direção esperada e usar colunas que existem.
4. Decisão: onde concentrar o programa de acompanhamento de alunos. Pergunta: quais turmas e perfis concentram mais evasão nos últimos 2 anos? Métrica: taxa de evasão por turma, turno e faixa de frequência. Dados: aluno, turma, turno, frequência, notas, situação financeira, data de matrícula e status (ativo ou evadido).
5. Volta para a coleta. Lá, verifica se o canal existe em outra fonte (outro sistema ou tabela que possa ser cruzada pelo código do pedido), registra a lacuna na documentação e, se não houver como obter, ajusta a pergunta para o que a base consegue responder.
6. Responde: como o faturamento evoluiu mês a mês; quais meses foram mais fortes no ano. Não responde: qual produto vende mais; qual dia da semana ou horário tem mais movimento; qual loja fatura mais (se o total for da rede). A granularidade mensal e agregada impede essas análises.

Capítulo 3 · Limpeza I: qualidade e diagnóstico

1. (a) Atualidade (e precisão): a data ainda não aconteceu. (b) Unicidade. (c) Consistência. (d) Completude. (e) Precisão: o valor não representa a realidade.
2. Depende do significado. Se o vazio quer dizer "o cliente ainda não cancelou", ele é informação e a coluna é valiosa: dá para criar a coluna "cancelou? sim/não". Excluir pela regra dos 40% seria um erro aqui. A regra vale para vazios que representam perda de informação.
3. Preencher com a mediana, porque ela não é puxada pelos valores muito altos, e registrar quais valores foram preenchidos. A média seria inadequada, porque os extremos a deixam acima do valor típico. Manter vazio também é defensável se a análise puder ignorar esses clientes, desde que isso seja registrado.
4. A mais recente (agosto), porque reflete o estado atual do cliente. Na planilha: ordenar `data_ultima_compra` da mais nova para a mais antiga e só então remover duplicatas marcando apenas `id_cliente`; a ferramenta mantém a primeira ocorrência, que é a mais recente.
5. Porque cria vários registros com exatamente o mesmo valor, no centro da distribuição. A variação (desvio padrão) cai artificialmente e a coluna parece mais homogênea do que é. Em análises de dispersão ou de correlação, isso pode enfraquecer ou mascarar relações reais.
6. O que foi feito: padronizei `canal` de 5 grafias para 2 valores (App e WhatsApp). Por quê: cada grafia era contada como um canal diferente. Risco de não fazer: contagens e comparações por canal erradas, com canais divididos em grupos falsos.

Capítulo 4 · Limpeza II e Preparação

1. (a) Impossível: desconto acima de 100% não existe. (b) Suspeito ou raro: pode ser uma escola comprando para a turma; vale investigar antes de mexer. (c) Raro ou normal: pode ser frete grátis por promoção; confira a regra do negócio. (d) Impossível na prática (a pessoa teria mais de 130 anos): é erro de registro.
2. IQR = 20 − 8 = 12. Cerca inferior = 8 − 1,5 × 12 = −10 (na prática, nenhum tempo fica abaixo). Cerca superior = 20 + 1,5 × 12 = 38. Como 45 é maior que 38, é marcado como outlier. Se for um atendimento real de um caso complexo, deve ser mantido e talvez analisado à parte.
3. Porque a cerca só diz que o valor está longe dos demais, e não se ele é verdadeiro. Um notebook de R$ 8.999 e um livro de R$ 5.373 passam da mesma cerca, mas só o segundo é erro. Quem separa um do outro é o conhecimento do produto, do cliente e da operação.
4. Uma coluna de dia da semana a partir da data e, a partir dela, uma coluna "fim de semana? sim/não". Sem essa coluna derivada, a comparação seria impossível, porque a data sozinha não agrupa os pedidos por tipo de dia.
5. Quase todos os clientes caíram na faixa do meio, deixando as outras quase vazias. Comparar grupos assim diz pouco. A correção é escolher limites pela distribuição (por exemplo, perto dos quartis, para grupos de tamanhos parecidos) ou por uma regra do negócio que faça sentido, e conferir as contagens de cada faixa.
6. Normalizar é (x − mínimo) ÷ (máximo − mínimo), com mínimo 10 e máximo 60, ou seja, divisão por 50. 10 → 0; 35 → 25 ÷ 50 = 0,5; 60 → 1.

Capítulo 5 · Exploração de Dados

1. A distribuição é assimétrica à direita: há alguns atendimentos muito demorados que puxam a média para cima. A maioria espera menos do que a média sugere; a mediana (9 minutos) descreve melhor a espera típica.
2. (a) Barras com a nota média (ou o percentual de notas 4 e 5) por cidade, mostrando o tamanho de cada grupo; ou boxplots, se a nota tiver muitos valores. (b) Gráfico de linha. (c) Dispersão. (d) Barras, na ordem Básico, Plus, Premium.
3. Não só com a contagem: o App tem muito mais clientes no total. É preciso usar o percentual por linha, comparando a fração de Premium dentro de cada canal. Na base de clientes, essa fração é maior na Loja do que no App, o contrário do que a contagem sugeria.
4. Que a diferença entre as cidades é pequena em relação à variação dentro de cada uma e pode ser só acaso. Não dá para afirmar que uma cidade gasta mais. O próximo passo seria olhar o tamanho de cada grupo e testar a diferença com mais cuidado.
5. Não necessariamente. Dezembro costuma ser mais forte por sazonalidade (fim de ano). Para avaliar crescimento, compare dezembro deste ano com dezembro do ano anterior, ou olhe a tendência ao longo de vários meses.
6. Exemplos: "a renda aumenta com a idade até por volta dos 50 anos e depois diminui"; "clientes acima de 60 anos têm renda menor que os de 40 a 50". Repare que a relação é curva: a correlação linear pode sair perto de zero mesmo com esse padrão claro.

Capítulo 6 · Estatística Descritiva

1. Média = (2.000 + 2.200 + 2.500 + 2.800 + 30.000) ÷ 5 = 39.500 ÷ 5 = R$ 7.900. Mediana = R$ 2.500 (o valor do meio). A mediana descreve melhor: nenhum funcionário típico ganha perto de R$ 7.900; o salário de R$ 30.000 puxa a média.
2. A turma A é homogênea: quase todos tiraram entre 6,5 e 7,5. A turma B é heterogênea: há alunos com notas bem baixas e bem altas. Para a turma B, pode valer separar grupos e dar apoio diferente a quem ficou abaixo.
3. (a) Forte e positiva. (b) Moderada e negativa. (c) Fraca e positiva (praticamente nenhuma relação). (d) Forte e negativa.
4. Não. Há uma terceira variável: o tamanho do incêndio. Incêndios maiores recebem mais bombeiros e causam mais prejuízo. A correlação é real, mas não é causa. É o mesmo raciocínio do sorvete e dos afogamentos.
5. (1) Olhar o gráfico de dispersão, porque pode haver uma relação em curva que a correlação não capta. (2) Calcular a correlação dentro de grupos (por cidade, por plano), porque ela pode existir só em alguns segmentos. (3) Verificar se algum extremo está distorcendo o resultado.
6. Exemplo: "Clientes Premium gastam em média R$ 746 por mês, quatro vezes mais que os do Básico (R$ 186), e as faixas de gasto dos dois planos quase não se sobrepõem. Migrar parte dos clientes Plus de renda mais alta para o Premium tem potencial de aumentar a receita; vale testar uma oferta de upgrade." O insight tem o quê, quanto, com quem e uma ação.

Capítulo 7 · Projeto Integrador

1. Está mal definida: "jovens" e "compram mais" não estão especificados. Uma versão testável: "clientes de até 30 anos fazem, em média, mais pedidos por mês do que clientes acima de 30 anos" (comparação de médias, com uma coluna derivada de faixa etária) ou "quanto menor a idade, maior o número de pedidos por mês" (correlação).
2. (a) Correlação: duas variáveis numéricas. (b) Comparação de médias: uma numérica (valor) entre dois grupos (com e sem cupom). (c) Análise por grupos: uma numérica entre vários grupos (bairros), com boxplots ou médias por bairro.
3. Não necessariamente. Uma correlação fraca não prova que não há efeito; pode haver poucos casos, uma relação curva ou um efeito só em alguns grupos. "Inconclusivo", com essa explicação, é o veredito mais honesto, a menos que o grupo mostre evidência clara de ausência de efeito (por exemplo, médias praticamente iguais entre faixas de desconto, com grupos grandes).
4. Exemplo: "40% dos pedidos estão sem cidade, o que impediu comparar regiões. Recomendamos tornar a cidade obrigatória no checkout e preenchê-la a partir do CEP, para que a próxima análise possa avaliar o desempenho por região." O insight tem o problema, o número, o impacto e a ação.
5. Exemplo: "O gestor pode priorizar pedidos acima de 6 km em dias de chuva, ampliando o prazo prometido em 10 minutos: nesses casos o tempo sobe cerca de um terço e a nota cai. Os dados não incluem o tempo de preparo no restaurante, então parte do atraso pode vir da cozinha."

APÊNDICE D

D PARA CONTINUAR ESTUDANDO

Esta disciplina é a base. O material complementar da disciplina traz uma trilha completa de continuidade; aqui vai um resumo das próximas estações, na ordem em que elas se apoiam no que você aprendeu.

PRÓXIMO PASSO	O QUE APRENDER	ESTENDE O CAPÍTULO
Pensamento estatístico	Distribuições, variabilidade, amostra e população, leitura crítica de números	6
Estatística inferencial	Intervalos de confiança, testes de hipótese, valor-p, regressão linear	2, 6
SQL	Consultar, filtrar, agrupar e cruzar dados direto em bancos de dados	3, 4
Python e pandas	Limpeza, exploração e estatística reprodutíveis em código	3 a 6
Visualização e dashboards	Escolher o gráfico certo, Power BI, Looker Studio, Matplotlib	5
Comunicação com dados	Narrativa, contexto antes do número, gráficos que não enganam	2, 7

Alguns recursos gratuitos para começar:

Khan Academy
Estatística e probabilidade do zero, em português.

Seeing Theory
Estatística com visualizações interativas.

OpenIntro Statistics
Livro completo e gratuito, da descritiva à inferência.

Kaggle Learn
Cursos curtos e práticos de pandas, SQL e visualização.

Base dos Dados
Bases públicas brasileiras já organizadas para praticar.

Storytelling with Data
Referência prática em comunicação com dados.

O conselho mais importante vale para qualquer trilha: praticar ensina mais do que assistir. A cada assunto novo, abra uma base de verdade e refaça. Uma estação por vez.